



Universidade Federal do Ceará
Centro de Tecnologia
Departamento de Engenharia de Teleinformática
Filtragem Adaptativa - TIP7188

Lista de Exercícios

Aluno: Lucas de Souza Abdalah (539567)

Professor: Charles Casimiro Cavalcante e Guilherme de Alencar Barreto

Data de Entrega: 20/07/2022

Fortaleza
2022

Sumário

1	Lista 1: Estatísticas de Segunda Ordem	2
1.1	Média e Autocorrelação	2
1.2	Processos Escationários	2
1.3	Matriz de Autocorrelação	4
1.4	Matriz Definida Positiva	5
1.5	Covariância e correlação	6
1.6	Função de autocorrelação	7
1.7	Exercícios Propostos	9
2	Lista 2: Filtragem Linear Ótima	11
2.1	Filtragem Ótima	11
2.2	Erro Médio Quadrático Mínimo	12
2.3	Cancelamento de Ruído	12
2.4	Predição Ótima	13
2.5	Superfície de Erro	14
2.6	Exercícios Propostos	16
3	Lista 3: Algoritmos Recursivos	18
3.1	Algoritmo LMF	18
3.2	Algoritmo LMS	19
3.3	Algoritmo LMS Normalizado	23
3.4	Equalização de Canais	24
3.4.1	Equalizado Ótimo e plano Z	24
3.4.2	Filtro de Erro de Predição Direta de Passo Unitário	25
3.4.3	Curvas de MSE e de Nível dos algoritmos	26
3.4.4	Número de condicionamento	29
3.4.5	Modelo de canal para número de condicionamento menor/maior que 5	29
3.5	Identificação de Sistemas	31
3.6	Equalização Adaptativa	36
3.7	Exercícios Propostos	41
4	Lista 4: Método dos Mínimos Quadrados	43
4.1	Algoritmo RLS	43
4.2	Erro de Estimação a Priori	44
4.3	Preditor Adaptativo	45
4.4	Equalização de Canais	50
4.5	Equalização Adaptativa	50
4.6	Exercícios Propostos	55
5	Implementações em MATLAB	56
5.1	Métodos	57
5.2	Função Main	93

1 Lista 1: Estatísticas de Segunda Ordem

1.1 Média e Autocorrelação

Ok

Para obter a média, basta a expressão de acordo com o operador esperança $\mathbb{E}\{\cdot\}$, dado que as variáveis aleatórias tem mesma média, resume-se a expressão:

$$\begin{aligned}\mathbb{E}\{x(n)\} &= \mathbb{E}\{v(n) + 3v(n-1)\} \\ &= \mu + 3\mu \\ &= 4\mu\end{aligned}$$

Já a variância, é obtida aplicando o mesmo operador, "abrindo" o termo ao quadrado, reorganizando em função do termo σ^2 e sabendo que $v(n)$ e $v(n-1)$ são descorrelacionadas:

$$\begin{aligned}\mathbb{E}\{[(x(n) - \mu_X)]^2\} &= \mathbb{E}\{[v(n) - 3v(n-1) - \mu_X]^2\} \\ &= \mathbb{E}\{[v(n) - 3v(n-1) - 4\mu]^2\} \\ &= \mathbb{E}\{[v(n) - \mu + 3v(n-1) - 3\mu]^2\} \\ &= \sigma^2 + 9\sigma^2 + \mathbb{E}\{6[v(n) - \mu][v(n-1) - \mu]\} \\ &= 10\sigma^2\end{aligned}$$

Para afirmar que o processo apresentado é estacionário em sentido amplo, abreviado em inglês para **WSS**, as estatísticas de primeira e de segunda ordem devem ser independentes ao deslocamento no tempo. Isto pode ser observado, assumindo novamente que $x(n)$ e $x(n+\tau)$, via função de correlação, dada por:

$$\begin{aligned}\mathbb{E}\{x(n)x(n+\tau)\} &= \mathbb{E}\{[v(n) + 3v(n-1)][v(n+\tau) + 3v(n-1+\tau)]\}, \\ &= \mathbb{E}\{v(n)v(n+\tau) + 3v(n)v(n-1+\tau) + 3v(n-1)v(n+\tau) + 9v(n-1)v(n-1+\tau)\} \\ &= \mathbb{E}\{\mu^2 + 3\mu^2 + 3\mu^2 + 9\mu^2\} \\ &= 16\mu^2\end{aligned}$$

Visto que os pré-requisitos são cumpridos, pode-se concluir que o processo é de fato WSS. Entretanto, para afirmar algo além disso é necessário conhecer os movimentos de ordem superior do caso estudado.

1.2 Processos Escationários

Organizar

$$x(n) = v_1(n) + 3v_2(n-1), \quad (1.1)$$

$$y(n) = v_2(n+1) + 3v_1(n-1), \quad (1.2)$$

em que $v_1(n)$ e $v_2(n)$ são processos de ruído branco independentes cada um com variância igual a 0,5.

item

Quais são as funções de autocorrelação de x e de y ? Os processos são WSS?

Solução:

Antes de tudo é de interesse definir o processo estocástico de ruído branco. Um processo desse tipo é formado por um número qualquer de amostras independentes entre si e com média nula. Desse modo, uma vez que a média de processos de ruído branco são nulas é possível obter facilmente a média dos novos processos formados pela combinação dos ruídos

$$\mathbb{E}\{x(n)\} = \mathbb{E}\{v_1(n) + 3v_2(n-1)\} = \mu_1 + 3\mu_2 = 0, \quad (1.3)$$

$$\mathbb{E}\{y(n)\} = \mathbb{E}\{v_2(n+1) + 3v_1(n-1)\} = \mu_2 + 3\mu_1 = 0. \quad (1.4)$$

Para a variância teremos uma resposta similar

$$\begin{aligned} \mathbb{E}\{[x(n) - \mu]^2\} &= \mathbb{E}\{[x(n) - 0]^2\} = \mathbb{E}\{[x(n)]^2\}, \\ \mathbb{E}\{[x(n) - \mu]^2\} &= \mathbb{E}\{[v_1(n) + 3v_2(n-1)]^2\} = \mathbb{E}\{[v_1^2(n)] + 6[v_1(n)v_2(n-1)] + 9[v_2^2(n-1)]\}, \\ \mathbb{E}\{[y(n) - \mu]^2\} &= \mathbb{E}\{[y(n) - 0]^2\} = \mathbb{E}\{[y(n)]^2\}, \\ \mathbb{E}\{[y(n) - \mu]^2\} &= \mathbb{E}\{[v_2(n+1) + 3v_1(n-1)]^2\} = \mathbb{E}\{[v_2^2(n+1)] + 6[v_2(n+1)v_1(n-1)] + 9[v_1^2(n-1)]\}. \end{aligned}$$

Rescrevendo a expressão para obter a formula da variância e utilizando o fato dos processos de ruído serem descorrelacionados uma nova expressão é obtida

$$\mathbb{E}\{[x(n) - \mu]^2\} = \mathbb{E}\{[v_1^2(n) - 0] + 0 + 9[v_2^2(n-1) - 0]\}, \quad (1.5)$$

$$\mathbb{E}\{[x(n) - \mu]^2\} = \sigma_1^2 + 9\sigma_2^2 = 10 * 0.5 = 5, \quad (1.6)$$

$$\mathbb{E}\{[y(n) - \mu]^2\} = \mathbb{E}\{[v_2^2(n+1) - 0] + 0 + 9[v_1^2(n-1) - 0]\}, \quad (1.7)$$

$$\mathbb{E}\{[y(n) - \mu]^2\} = \sigma_2^2 + 9\sigma_1^2 = 10 * 0.5 = 5. \quad (1.8)$$

A função de autocorrelação para X é calculada como se segue

$$r_x(\tau) = \mathbb{E}\{x(n)x(n+\tau)\} = \mathbb{E}\{[v_1(n) + 3v_2(n-1)][v_1(n+\tau) + 3v_2(n-1+\tau)]\}, \quad (1.9)$$

$$r_x(\tau) = \mathbb{E}\{[v_1(n)v_1(n+\tau)] + 3[v_1(n)v_2(n-1+\tau)] + 3[v_2(n-1)v_1(n+\tau)] \quad (1.10)$$

$$+ 9[v_2(n-1)v_2(n-1+\tau)]\}. \quad (1.11)$$

Sabendo que amostras de um mesmo processo são descorrelacionadas e que ambos os processos também são descorrelacionados, além de termos conhecimento de que ambos possuem média nula, então

$$\mathbb{E}\{[v_1(n)v_1(n+\tau)]\} = \mathbb{E}\{[v_1(n)]\}\mathbb{E}\{[v_1(n+\tau)]\} = 0, \quad (1.12)$$

$$3\mathbb{E}\{[v_1(n)v_2(n-1+\tau)]\} = 3\mathbb{E}\{[v_1(n)]\}\mathbb{E}\{[v_2(n-1+\tau)]\} = 0, \quad (1.13)$$

$$3\mathbb{E}\{[v_2(n-1)v_1(n+\tau)]\} = 3\mathbb{E}\{[v_2(n-1)]\}\mathbb{E}\{[v_1(n+\tau)]\} = 0, \quad (1.14)$$

$$9\mathbb{E}\{[v_2(n-1)v_2(n-1+\tau)]\} = 9\mathbb{E}\{[v_2(n-1)]\}\mathbb{E}\{[v_2(n-1+\tau)]\} = 0, \quad (1.15)$$

$$r_x(\tau) = 0. \quad (1.16)$$

Repetindo o procedimento para Y e omitindo informações redundantes chega-se ao seguinte resultado

$$r_y(\tau) = 0. \quad (1.17)$$

Sendo as estatísticas de primeira e de segunda ordem independentes quanto ao tempo para os dois processos então é possível afirmar que eles são WSS.

item

Qual é a função de correlação cruzada $r_{xy}(n_1, n_0)$? Estes processos são conjuntamente estacionários (no sentido amplo)? Justifique.

Solução:

$$r_{x,y}(n_1, n_0) = \mathbb{E}\{[x(n_1)y^*(n_0)]\} = \mathbb{E}\{[v_1(n_1) + 3v_2(n_1 - 1)][v_2(n_0 + 1) + 3v_1(n_0 - 1)]^*\}, \quad (1.18)$$

$$r_{x,y}(n_1, n_0) = \mathbb{E}\{[v_1(n_1)v_2^*(n_0 + 1)] + 3[v_1(n_1)v_1^*(n_0 - 1)] + 3[v_2(n_1 - 1)v_2^*(n_0 + 1)] \quad (1.19)$$

$$+ 9[v_2(n_1 - 1)v_1^*(n_0 - 1)]\}. \quad (1.20)$$

Novamente considerando que os processos de ruído branco são descorrelacionadas entre si e que as amostras individuais são também independentes então podemos simplificar a expressão acima da seguinte forma

$$r_{x,y}(n_1, n_0) = 0 \quad (1.21)$$

Sendo assim, os processos podem ser considerados conjuntamente estacionários uma vez que a correlação cruzada é independente do instante temporal e que os processos que compoem o processo conjunto podem ser considerados estacionários em sentido amplo isoladamente. Entretanto, vale notar que foi possível realizar tal afirmação apenas por termos conhecimento da relação de independência entre os processos de ruído branco, pois de outro modo não seria possível realizar afirmações quanto a correlação cruzada do processo conjunto.

1.3 Matriz de Autocorrelação

Organizar

$$\mathbf{R} = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \quad (1.22)$$

devem satisfazer tal que \mathbf{R} seja uma matriz de autocorrelação válida de

item

Um vetor aleatório bidimensional?

Solução:

Em suma, precisamos estar atentos às seguintes propriedades para garantir que temos em mãos uma matriz de autocorrelação válida

- $\mathbf{R}_x = \mathbf{R}_x^H$
- $\mathbf{a}^H \mathbf{R}_{xa} \geq 0$
- $\mathbf{A} \mathbf{x} = \lambda \mathbf{x}, \forall \lambda \geq 0$ and $\mathbf{x} \in \mathbb{R}$

Desse modo, considerando um vetor aleatório bidimensional descrito por $\mathbf{X} = (x_1, x_2)$ podemos então

$$\mathbf{R} = \begin{bmatrix} \mathbb{E}\{[x_1^2]\} & \mathbb{E}\{[x_1 x_2^*]\} \\ \mathbb{E}\{[x_2 x_1^*]\} & \mathbb{E}\{[x_2^2]\} \end{bmatrix}, \quad (1.23)$$

$$\mathbf{R}^H = \begin{bmatrix} \mathbb{E}\{[x_1^2]\} & \mathbb{E}\{[x_2 x_1^*]\} \\ \mathbb{E}\{[x_1 x_2^*]\} & \mathbb{E}\{[x_2^2]\} \end{bmatrix}. \quad (1.24)$$

Inicialmente, podemos garantir a simetria quanto ao hermitiano se fizermos

$$\mathbb{E}\{[x_1 x_2^*]\} \triangleq \mathbb{E}\{[x_2 x_1^*]\}, \quad \mathbb{E}\{[x_2 x_1^*]\} \triangleq \mathbb{E}\{[x_1 x_2^*]\}. \quad (1.25)$$

Entretanto, sabemos que o operador esperança é linear tornando assim as expressões acima equivalentes. Em continuidade do problema, podemos considerar que a restrição as quais os autovalores estão submetidos pode ser facilmente atingida ao garantirmos que o determinante da matriz de correlação seja maior que a nulidade

$$\mathbb{E}\{[x_1^2]\}\mathbb{E}\{[x_2^2]\} - \mathbb{E}\{[x_1 x_2]\}\mathbb{E}\{[x_2 x_1]\} > 0, \quad (1.26)$$

$$\mathbb{E}\{[x_1^2]\}\mathbb{E}\{[x_2^2]\} > \mathbb{E}\{[x_1 x_2]\}\mathbb{E}\{[x_2 x_1]\}. \quad (1.27)$$

item

Um processo estocástico estacionário escalar?

Solução:

Considerando um processo estocástico estacionário escalar do tipo $\mathbf{X}_t = x(t)$ e uma versão atrasada desse processo definida por $\mathbf{X}_{t+\tau} = x(t + \tau)$ temos que a matriz de correlação pode ser escrita da seguinte forma

$$\mathbf{R} = \begin{bmatrix} \mathbb{E}\{[x^2(t)]\} & \mathbb{E}\{[x(t)x^*(t+\tau)]\} \\ \mathbb{E}\{[x(t+\tau)x^*(t)]\} & \mathbb{E}\{[x^2(t+\tau)]\} \end{bmatrix}, \quad (1.28)$$

$$\mathbf{R}^H = \begin{bmatrix} \mathbb{E}\{[x^2(t)]\} & \mathbb{E}\{[x(t+\tau)x^*(t)]\} \\ \mathbb{E}\{[x(t)x^*(t+\tau)]\} & \mathbb{E}\{[x^2(t+\tau)]\} \end{bmatrix}. \quad (1.29)$$

Em sequência, podemos garantir a simetria quanto ao hermitiano se fizermos

$$\mathbb{E}\{[x(t)x^*(t+\tau)]\} \triangleq \mathbb{E}\{[x(t+\tau)x^*(t)]\}, \quad (1.30)$$

$$\mathbb{E}\{[x(t+\tau)x^*(t)]\} \triangleq \mathbb{E}\{[x(t)x^*(t+\tau)]\}, \quad (1.31)$$

mas, mais uma vez, considerando que o operador esperança é linear então as duas expressões são equivalentes. Já considerando a restrição imposta aos autovalores da matriz temos novamente

$$\mathbb{E}\{[x^2(t)]\}\mathbb{E}\{[x^2(t+\tau)]\} > \mathbb{E}\{[x(t)x^*(t+\tau)]\}\mathbb{E}\{[x(t+\tau)x^*(t)]\}. \quad (1.32)$$

1.4 Matriz Definida Positiva

Organizar

$$\mathbb{E}\{\mathbf{x}^H \mathbf{R}_x^{-1} \mathbf{x}\} = N \quad (1.33)$$

Solução:

Inicialmente podemos escrever a expressão regular para a matriz de autocorrelação e supondo que de fato existe uma inversa bem definida para a matriz de autocorrelação

$$\mathbb{E}\{\mathbf{x}\mathbf{x}^H\} = \mathbf{R}_x, \quad (1.34)$$

$$\mathbb{E}\{\mathbf{x}\mathbf{x}^H\}\mathbf{R}_x^{-1} = \mathbf{R}_x\mathbf{R}_x^{-1}, \quad (1.35)$$

$$\mathbb{E}\{\mathbf{x}\mathbf{x}^H\mathbf{R}_x^{-1}\} = \mathbf{I}_N, \quad (1.36)$$

$$(1.37)$$

Desse modo, podemos aplicar o operador traço de matriz e por meio da propriedade de permutação cíclica desse operador chegamos ao seguinte resultado

$$\text{Tr}\{\mathbb{E}\{\mathbf{x}\mathbf{x}^H\mathbf{R}_x^{-1}\}\} = \text{Tr}\{\mathbf{I}_N\}, \quad (1.38)$$

$$\text{Tr}\{\mathbb{E}\{\mathbf{x}^H\mathbf{R}_x^{-1}\mathbf{x}\}\} = \text{Tr}\{\mathbf{I}_N\}, \quad (1.39)$$

$$\text{Tr}\{\mathbb{E}\{\mathbf{x}^H\mathbf{R}_x^{-1}\mathbf{x}\}\} = N, \quad (1.40)$$

onde a ultima expressão se justifica pois temos uma matriz identidade de ordem N no lado direito. Desse modo, seu traço é dado por $\sum_{i=1}^N 1 = N$.

1.5 Covariância e correlação

Organizar

item

$$\mathbf{R}_x = \mathbf{C}_x + \mu_x \mu_x^H$$

Solução:

$$C_X = \mathbb{E}\{(x - \mu)(x - \mu)^H\} = \mathbb{E}\{xx^H - x\mu^H - \mu x^H + \mu\mu^H\}, \quad (1.41)$$

$$C_X = \mathbb{E}\{xx^H\} - \mathbb{E}\{x\mu^H\} - \mathbb{E}\{\mu x^H\} + \mathbb{E}\{\mu\mu^H\}. \quad (1.42)$$

Considerando a matriz de correlação pode ser escrita por $R_X = \mathbb{E}\{xx^H\}$ e que o valor médio de um escalar é o próprio escalar temos

$$C_X = R_X - \mathbb{E}\{x\mu^H\} - \mathbb{E}\{\mu x^H\} + \mu\mu^H, \quad (1.43)$$

$$C_X = R_X - \mu^H \mathbb{E}\{x\} - \mu \mathbb{E}\{x^H\} + \mu\mu^H, \quad (1.44)$$

$$C_X = R_X - \mu\mu^H - \mu\mu^H + \mu\mu^H, \quad (1.45)$$

$$C_X = R_X - \mu\mu^H, \quad (1.46)$$

$$R_X = C_X + \mu\mu^H. \quad (1.47)$$

item

$$\mathbf{C}_{\mathbf{x}+\mathbf{y}} = \mathbf{C}_x + \mathbf{C}_y, \text{ para } \mathbf{x} \text{ e } \mathbf{y} \text{ descorrelacionados}$$

Solução:

$$\mathbf{C}_{\mathbf{x}+\mathbf{y}} = \mathbf{C}_x + \mathbf{C}_{xy} + \mathbf{C}_{yx} + \mathbf{C}_y. \quad (1.48)$$

Onde os termos de correlação cruzada \mathbf{C}_{xy} e \mathbf{C}_{yx} podem ser obtidos da seguinte maneira

$$\mathbf{C}_{\mathbf{xy}} = \mathbb{E}\{[x - \mu_x][y - \mu_y]\}, \quad (1.49)$$

$$\mathbf{C}_{\mathbf{xy}} = \mathbb{E}\{[xy]\} - \mathbb{E}\{[x\mu_y]\} - \mathbb{E}\{[\mu_x y]\} + \mathbb{E}\{[\mu_x \mu_y]\}, \quad (1.50)$$

$$\mathbf{C}_{\mathbf{xy}} = \mathbb{E}\{[xy]\} - \mu_y \mu_x - \mu_x \mu_y + \mu_x \mu_y, \quad (1.51)$$

$$\mathbf{C}_{\mathbf{xy}} = \mathbb{E}\{[xy]\} + \mu_x \mu_y, \quad (1.52)$$

$$\mathbf{C}_{\mathbf{xy}} = \mu_x \mu_y, \quad (1.53)$$

$$(1.54)$$

$$\mathbf{C}_{\mathbf{yx}} = \mathbb{E}\{[y - \mu_y][x - \mu_x]\}, \quad (1.55)$$

$$\mathbf{C}_{\mathbf{yx}} = \mathbb{E}\{[yx]\} - \mathbb{E}\{[y\mu_x]\} - \mathbb{E}\{[\mu_y x]\} + \mathbb{E}\{[\mu_y \mu_x]\}, \quad (1.56)$$

$$\mathbf{C}_{\mathbf{yx}} = \mathbb{E}\{[yx]\} - \mu_y \mu_x - \mu_x \mu_y + \mu_y \mu_x, \quad (1.57)$$

$$\mathbf{C}_{\mathbf{yx}} = \mathbb{E}\{[yx]\} - \mu_x \mu_y, \quad (1.58)$$

$$\mathbf{C}_{\mathbf{yx}} = -\mu_x \mu_y. \quad (1.59)$$

Portanto, é possível afirmar que a soma dos termos de correlação cruzada é nula e que a correlação da soma de dois vetores descorrelacionados é de fato dada por $\mathbf{C}_{\mathbf{x+y}} = \mathbf{C}_{\mathbf{x}} + \mathbf{C}_{\mathbf{y}}$

$$\mathbf{C}_{\mathbf{xy}} + \mathbf{C}_{\mathbf{yx}} = \mu_x \mu_y - \mu_x \mu_y, \quad (1.60)$$

$$\mathbf{C}_{\mathbf{xy}} + \mathbf{C}_{\mathbf{yx}} = 0. \quad (1.61)$$

1.6 Função de autocorrelação

Organizar

$$x(n) = v_1(n) + 2v_1(n+1) + 3v_2(n-1)? \quad (1.62)$$

Este é um processo WSS? Justifique.

Solução:

Para simplificar o desenvolvimento iremos considerar que os processos possuem media nula e são descorrelacionados

$$r_x = \mathbb{E}\{x(n)x^*(n)\},$$

$$r_x = \mathbb{E}\{[v_1(n) + 2v_1(n+1) + 3v_2(n-1)][v_1(n) + 2v_1(n+1) + 3v_2(n-1)]^*(n)\},$$

$$r_x = \mathbb{E}\{[v_1(n)v_1^*(n) + 2v_1(n)v_1^*(n+1) + 3v_1(n)v_2^*(n-1) + 2v_1(n+1)v_1^*(n) + 4v_1(n+1)v_1^*(n+1) + 6v_1(n+1)v_2^*(n-1)] + 3v_2(n-1)v_1^*(n) + 6v_2(n-1)v_1^*(n+1) + 9v_2(n-1)v_2^*(n-1)\},$$

$$r_x = r_v(n, n) + 2r_v(n, n+1) + 0 + 2r_v(n+1, n) + 4r_v(n+1, n+1) + 0 + 0 + 0 + 9r_v(n-1, n-1),$$

$$r_x = r_v(n, n) + 2r_v(n, n+1) + 2r_v(n+1, n) + 4r_v(n+1, n+1) + 9r_v(n-1, n-1).$$

Após uma breve análise na expressão $r_v(n_1, n_0)$ é possível verificar que determinados termos anulam-se ao considerar um único momento temporal devido a presença da função degrau unitário, permitindo a seguinte simplificação:

$$r_x = 2r_v(n, n+1) + 2r_v(n+1, n), \quad (1.63)$$

$$r_x = \delta(n - n - 1) + \delta(n + 1 - n). \quad (1.64)$$

Onde a generalização pode ser descrita por:

$$r_x(n_1, n_2) = \delta(n_1 - n_2) + \delta(n_2 - n_1). \quad (1.65)$$

Uma vez que a correlação é dependente apenas de um deslocamento temporal, então podemos classificar esse processo como WSS.

item

Encontre a a matrix de correlação de um vetor aleatório consistindo de oito amostras consecutivas de $x(n)$.

Solução:

$$\mathbf{R}_x = \begin{bmatrix} 2 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 2 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 2 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 2 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 2 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 2 \end{bmatrix} \quad (1.66)$$

Para chegar a esse resultado foi utilizado a expressão para a correlação obtida no item anterior. Uma vez que a função delta de dirac terá um valor não nulo apenas quando o argumento for zero, isso irá acontecer apenas quando os momentos n_1 e n_2 forem iguais e isso irá acontecer apenas com os elementos da diagonal principal.



Filtragem Adaptativa - TIP 7188

Prof. Dr. Charles Casimiro Cavalcante
Prof. Dr. Guilherme de Alencar Barreto

Período: 2022.2

Lista de Exercícios No. 1: Estatísticas de Segunda Ordem

- 1. (Média e autocorrelação)** Determine a média e a função de autocorrelação para o processo aleatório

$$x(n) = v(n) + 3v(n-1)$$

em que $v(n)$ é uma sequência de variáveis aleatórias independentes com média μ e variância σ^2 . $x(n)$ é estacionário? Justifique.

- 2. (Processos estacionários)** Sejam os processos aleatórios $x(n)$ e $y(n)$ definidos por

$$x(n) = v_1(n) + 3v_2(n-1)$$

e

$$y(n) = v_2(n+1) + 3v_1(n-1)$$

em que $v_1(n)$ e $v_2(n)$ são processos de ruído branco independentes cada um com variância igual a 0,5.

- (a) Quais são as funções de autocorrelação de x e de y ? Os processos são WSS?
(b) Qual é a função de correlação cruzada $r_{xy}(n_1, n_0)$? Estes processos são conjuntamente estacionários (no sentido amplo)? Justifique.

- 3. (Matriz de autocorrelação)** Quais as condições que os elementos de uma matriz

$$\mathbf{R} = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

devem satisfazer tal que \mathbf{R} seja uma matriz de autocorrelação válida de

- (a) Um vetor aleatório bidimensional?
(b) Um processo estocástico estacionário escalar?

- 4. (Matriz definida positiva)** Assuma que a inversa \mathbf{R}_x^{-1} da matriz de autocorrelação de um vetor coluna N -dimensional exista. Mostre que

$$E \{ \mathbf{x}^H \mathbf{R}_x^{-1} \mathbf{x} \} = N$$

- 5. (Covariância e correlação)** Mostre que as matrizes de correlação e covariância satisfazem as relações abaixo:

- $\mathbf{R}_x = \mathbf{C}_x + \boldsymbol{\mu}_x \boldsymbol{\mu}_x^H$
- $\mathbf{C}_{x+y} = \mathbf{C}_x + \mathbf{C}_{xy} + \mathbf{C}_{yx} + \mathbf{C}_y$, para \mathbf{x} e \mathbf{y} descorrelacionados



- 6. (Função de autocorrelação)** Processos aleatórios $v_1(n)$ e $v_2(n)$ são independentes e têm a mesma função de correlação

$$r_v(n_1, n_0) = 0.5\delta(n_1 - n_0)$$

- (a) Qual é a função de correlação do processo aleatório

$$x(n) = v_1(n) + 2v_1(n+1) + 3v_2(n-1)?$$

Este é um processo WSS? Justifique.

- (b) Encontre a a matrix de correlação de um vetor aleatório consistindo de oito amostras consecutivas de $x(n)$.

2 Lista 2: Filtragem Linear Ótima

2.1 Filtragem Ótima

Coeficientes de Wiener

Considerando o problema de filtragem de Wiener, e assumindo conhecimento da matriz de correlação \mathbf{R}_X e do vetor de correlação cruzada \mathbf{p}_{Xd} , pode-se obter os coeficientes de \mathbf{w} .

$$\mathbf{w} = \mathbf{R}_X^{-1} \mathbf{p}_{Xd} \quad (2.1)$$

Aplicando a equação 2.1, obtém-se o vetor de pesos do filtro.

$$\mathbf{R}_X^{-1} = \begin{bmatrix} 1.3333 & -0.6667 \\ -0.6667 & 1.3333 \end{bmatrix}$$

$$\begin{aligned} \mathbf{w} &= \begin{bmatrix} 1.3333 & -0.6667 \\ -0.6667 & 1.3333 \end{bmatrix} \begin{bmatrix} 0.5 \\ 0.25 \end{bmatrix} \\ &= \begin{bmatrix} 0.5 \\ 0 \end{bmatrix}. \end{aligned}$$

Erro Médio Quadrático

A partir do vetor de pesos, resultado de 2.1, basta aplicá-lo na equação do erro mínimo.

$$\mathbb{E}\{e^2(n)\} = \sigma_d^2 - 2\mathbf{w}^\top \mathbf{p}_{Xd} + \mathbf{w}^\top \mathbf{R}_X \mathbf{w} \quad (2.2)$$

$$\begin{aligned} e &= \sigma_d^2 - 2 \begin{bmatrix} 0.5 & 0.0 \end{bmatrix} \begin{bmatrix} 0.5 \\ 0.25 \end{bmatrix} + \begin{bmatrix} 0.5 & 0.0 \end{bmatrix} \begin{bmatrix} 1 & -0.5 \\ -0.5 & 1 \end{bmatrix} \begin{bmatrix} 0.5 \\ 0.0 \end{bmatrix} \\ &= \sigma_d^2 - 2 \times 0.25 + 0.25 \\ &= \sigma_d^2 - 0.25 \end{aligned}$$

Representação em Autovalores

A decomposição em valores singulares (EVD) pode ser aplicada na matriz de correlação

$$\mathbf{R}_X = \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^{-1} \quad (2.3)$$

Aplicando diretamente o resultado da EVD 2.3 na equação do filtro ótimo 2.1, obtém-se:

$$\mathbf{w} = (\mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^{-1})^{-1} \mathbf{p}_{Xd} \quad (2.4)$$

Finalmente, o resultado é uma expressão que compreende a inversão de matrizes menos custosas computacionalmente. Isto se dá principalmente por $\mathbf{\Lambda}$ ser uma matriz diagonal contendo os autovalores da matriz de autocorrelação, bastando calcular $1/\lambda_i$ para obter a sua inversa.

$$\mathbf{w} = \mathbf{Q}^{-1} \mathbf{\Lambda}^{-1} \mathbf{Q} \mathbf{p}_{Xd}. \quad (2.5)$$

2.2 Erro Médio Quadrático Mínimo

Para verificar a expressão proposta, é necessário obter a matriz de correlação do vetor aumentado.

$$\begin{aligned}\mathbf{A} &= \mathbb{E} \left\{ \begin{bmatrix} d(n) \\ x(n) \end{bmatrix} \begin{bmatrix} d(n)^\top & x(n)^\top \end{bmatrix} \right\} \\ &= \begin{bmatrix} \mathbb{E}\{d(n)d(n)^\top\} & \mathbb{E}\{d(n)x(n)^\top\} \\ \mathbb{E}\{x(n)d(n)^\top\} & \mathbb{E}\{x(n)x(n)^\top\} \end{bmatrix} \\ &= \begin{bmatrix} \sigma_d^2 & \mathbf{p}_{\mathbf{X}d}^\top \\ \mathbf{p}_{\mathbf{X}d} & \mathbf{R}_X \end{bmatrix}\end{aligned}$$

É conveniente observar que ao desenvolver a equação, os elementos resultantes da expressão são todos conhecidos. Multiplicando o resultado obtido pelo vetor $\begin{bmatrix} 1 \\ -\mathbf{w} \end{bmatrix}$ à direita e assumindo o modelo nas condições de filtragem ótima, dado filtro de Wiener, onde, $\mathbf{w}_{\text{opt}} = \mathbf{R}_X^{-1} \mathbf{p}_{\mathbf{X}d}$, temos que:

$$\begin{aligned}\mathbf{A} \begin{bmatrix} 1 \\ -\mathbf{w} \end{bmatrix} &= \begin{bmatrix} \sigma_d^2 & \mathbf{p}_{\mathbf{X}d}^\top \\ \mathbf{p}_{\mathbf{X}d} & \mathbf{R}_X \end{bmatrix} \begin{bmatrix} 1 \\ -\mathbf{w} \end{bmatrix} \\ &= \begin{bmatrix} \sigma_d^2 - \mathbf{p}_{\mathbf{X}d}^\top \mathbf{w} \\ \mathbf{p}_{\mathbf{X}d} - \mathbf{R}_X \mathbf{w} \end{bmatrix} \\ &= \begin{bmatrix} \sigma_d^2 - \mathbf{p}_{\mathbf{X}d}^\top \mathbf{R}_X^{-1} \mathbf{p}_{\mathbf{X}d} \\ \mathbf{p}_{\mathbf{X}d} - \mathbf{R}_X \mathbf{R}_X^{-1} \mathbf{p}_{\mathbf{X}d} \end{bmatrix} \\ &= \begin{bmatrix} \sigma_d^2 - \mathbf{p}_{\mathbf{X}d}^\top \mathbf{R}_X^{-1} \mathbf{p}_{\mathbf{X}d} \\ \mathbf{p}_{\mathbf{X}d} - \mathbf{I}_X \mathbf{p}_{\mathbf{X}d} \end{bmatrix} \\ &= \begin{bmatrix} \sigma_d^2 - \mathbf{p}_{\mathbf{X}d}^\top \mathbf{R}_X^{-1} \mathbf{p}_{\mathbf{X}d} \\ 0 \end{bmatrix}\end{aligned}$$

Finalmente, dado a equação obtida, com expressão equivalente à J_{\min} , pode-se escrever a relação proposta.

$$\mathbf{A} \begin{bmatrix} 1 \\ -\mathbf{w} \end{bmatrix} = \begin{bmatrix} J_{\min} \\ 0 \end{bmatrix}$$

2.3 Cancelamento de Ruído

Organizar

Inicialmente é necessário calcular a equação de erro do sistema aqui proposto

$$e(n) = x(n) - \hat{v}_1 = x(n) - \mathbf{w}^T v_2(n) \quad (2.6)$$

Em seguida faz-necessário calcular a função mean square error(MSE) que é facilmente fornecida pela manipulação algébrica abaixo

$$e^2(n) = [x(n) - \mathbf{w}^T v_2(n)][x(n) - \mathbf{w}^T v_2(n)]^T, \quad (2.7)$$

$$e^2(n) = x^2(n) - 2x(n)\mathbf{w}^T v_2(n) + \mathbf{w}^T v_2(n)v_2^T \mathbf{w}. \quad (2.8)$$

Sendo considerado que o filtro apresenta coeficientes constantes é possível aplicar o operador Valor Esperado de forma a obter a seguinte relação

$$\mathbb{E}\{e^2(n)\} = \mathbb{E}\{x^2(n)\} - 2\mathbf{w}^T \mathbb{E}\{x(n)v_2(n)\} + \mathbf{w}^T \mathbb{E}\{v_2(n)v_2(n)^T\} \mathbf{w}, \quad (2.9)$$

$$\mathbb{E}\{e^2(n)\} = \sigma_x^2 - 2\mathbf{w}^T \mathbf{p}_{xv_2} + \mathbf{w}^T \mathbf{R}_{v_2} \mathbf{w}. \quad (2.10)$$

Por fim, basta encontrar o \mathbf{w} que minimiza o MSE acima. Para chegar a esse fim, calcula-se o gradiente quanto ao \mathbf{w} igualando-se o resultado da operação a zero

$$\nabla_{\mathbf{w}} \mathbb{E}\{e^2(n)\} = -2\mathbf{p}_{xv_2} + 2\mathbf{R}_{v_2} \mathbf{w} = 0, \quad (2.11)$$

$$-\mathbf{p}_{xv_2} + \mathbf{R}_{v_2} \mathbf{w} = 0, \quad (2.12)$$

$$\mathbf{R}_{v_2} \mathbf{w} = \mathbf{p}_{xv_2}. \quad (2.13)$$

Utilizando a identidade matricial abaixo é possível resolver a equação acima para obter o seguinte resultado

$$\mathbf{R}_{v_2}^{-1} \mathbf{R}_{v_2} \mathbf{w} = \mathbf{R}_{v_2}^{-1} \mathbf{p}_{xv_2}, \quad (2.14)$$

$$\mathbf{I} \mathbf{w} = \mathbf{R}_{v_2}^{-1} \mathbf{p}_{xv_2}, \quad (2.15)$$

$$\mathbf{w} = \mathbf{R}_{v_2}^{-1} \mathbf{p}_{xv_2}. \quad (2.16)$$

Onde é possível reescrever o termo final como

$$\mathbf{w} = \mathbf{R}_{v_2}^{-1} (\mathbf{p}_d + \mathbf{p}_{v_1} + \mathbf{p}_{v_2}) \quad (2.17)$$

2.4 Predição Ótima

Organizar

O filtro linear ótimo que minimiza o erro médio quadrático é descrito pela solução das equações de Wiener. Portanto, inicialmente definir a matriz de autocorrelação para o processo descrito por $x(n)$

$$\mathbf{R}_x = \begin{bmatrix} \mathbb{E}\{x(n)x^*(n)\} & \mathbb{E}\{x(n-1)x^*(n)\} \\ \mathbb{E}\{x(n)x^*(n-1)\} & \mathbb{E}\{x(n-1)x^*(n-1)\} \end{bmatrix}, \quad (2.18)$$

se considerarmos que o processo $S(n)$ é WSS com variância σ_s^2 podemos calcular as correlações como se segue

$$\begin{aligned} \mathbb{E}\{x(n)x^*(n)\} &= \mathbb{E}\{s(n-a)s^*(n-a) + s(n-a)s^*(n-4a) + s(n-4a)s^*(n-a) \\ &\quad + s(n-4a)s^*(n-4a)\} = \sigma_s^2 + 0 + 0 + \sigma_s^2 = 2\sigma_s^2, \end{aligned}$$

$$\begin{aligned} \mathbb{E}\{x(n-1)x^*(n)\} &= \mathbb{E}\{s(n-1-a)s^*(n-a) + s(n-1-a)s^*(n-4a) + s(n-1-4a)s^*(n-a) \\ &\quad + s(n-1-4a)s^*(n-4a)\} = 0 + 0 + 0 + 0 = 0, \end{aligned}$$

$$\begin{aligned} \mathbb{E}\{x(n)x^*(n-1)\} &= \mathbb{E}\{s(n-a)s^*(n-1-a) + s(n-a)s^*(n-1-4a) + s(n-4a)s^*(n-1-a) \\ &\quad + s(n-4a)s^*(n-1-4a)\} = 0 + 0 + 0 + 0 = 0, \end{aligned}$$

$$\begin{aligned} \mathbb{E}\{x(n-1)x^*(n-1)\} &= \mathbb{E}\{s(n-1-a)s^*(n-1-a) + s(n-1-a)s^*(n-1-4a) \\ &\quad + s(n-1-4a)s^*(n-1-a) + s(n-1-4a)s^*(n-1-4a)\} = \sigma_s^2 + 0 + 0 + \sigma_s^2 = 2\sigma_s^2 \end{aligned}$$

obtendo assim

$$\mathbf{R}_x = \begin{bmatrix} 2\sigma_s^2 & 0 \\ 0 & 2\sigma_s^2 \end{bmatrix}. \quad (2.19)$$

Entretanto, considerando que o processo $D(n)$ têm média nula então temos na verdade um vetor de correlação cruzada nulo. Desse modo, o filtro linear ótimo para esse processo seria o próprio vetor nulo. Sendo assim

$$\mathbf{w}_{\text{opt}} = \mathbf{R}_x^{-1} \mathbf{p}_{xd} = \begin{bmatrix} 2\sigma_s^2 & 0 \\ 0 & 2\sigma_s^2 \end{bmatrix} \begin{bmatrix} 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad (2.20)$$

2.5 Superfície de Erro

Organizar

A partir dos coeficientes fornecidos é possível escrever a matrix de correlação necessário para o filtro ótimo de wiener como uma matriz identidade de ordem 2

$$\mathbf{R}_X = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad (2.21)$$

Ao utilizar a solução fechada do problema chega-se ao seguinte vetor resultado

$$\mathbf{w}_{\text{opt}} = \mathbf{R}_x^{-1} \mathbf{p}_{xd} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 2 \\ 4.5 \end{bmatrix} = \begin{bmatrix} 2 \\ 4.5 \end{bmatrix}. \quad (2.22)$$

A superfície definida por $J(\mathbf{w})$. Faça um gráfico da mesma.

Solução:

Para obter a expressão que define a superfície basta desenvolver a expressão para o erro médio

$$\mathbf{J}(w) = \mathbb{E}\{e^2(n)\} = \sigma_d^2 - 2\mathbf{w}^T \mathbf{p}_{xd} + w^T \mathbf{R}_X \mathbf{w}. \quad (2.23)$$

Substituindo os valores encontrados anteriormente na expressão da superfície

$$\mathbf{J}(w_0, w_1) = 24.40 - 2[w_0 w_1] \begin{bmatrix} 2 \\ 4.5 \end{bmatrix} + [w_0 w_1] \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} w_0 \\ w_1 \end{bmatrix}, \quad (2.24)$$

$$\mathbf{J}(w_0, w_1) = 24.40 - 4w_0 - 9w_1 + w_0^2 + w_1^2. \quad (2.25)$$

Utilizando um software gráfico é possível obter a Figura 2.1 onde é traçada a superfície de erro MSE expressa na Equação (2.23).




Figura 2.1: Superfície de erro $J(w_0, w_1)$.

Filtragem Adaptativa - TIP 7188

Prof. Dr. Charles Casimiro Cavalcante
Prof. Dr. Guilherme de Alencar Barreto

Período: 2022.2

Lista de Exercícios No. 2: Filtragem Linear Ótima

- 1. (Filtragem ótima)** Considere um problema de filtragem de Wiener conforme caracterizado a seguir. A matriz de correlação \mathbf{R}_x de um vetor de entrada $\mathbf{x}(n)$ é dada por

$$\mathbf{R}_x = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix}.$$

O vetor de correlação cruzada \mathbf{p}_{xd} entre o vetor de entrada \mathbf{x} e a resposta desejada $d(n)$ é

$$\mathbf{p}_{xd} = \begin{bmatrix} 0.5 \\ 0.25 \end{bmatrix}$$

- (a) Encontre o vetor de coeficientes do filtro de Wiener.
- (b) Qual é o mínimo erro médio quadrático fornecido por este filtro?
- (c) Formule uma representação do filtro de Wiener em termos dos autovalores da matriz \mathbf{R}_x e de seus autovetores associados.

- 2. (Erro médio quadrático mínimo)** Mostre que a equação do erro mínimo pode se escrita da seguinte maneira:

$$\mathbf{A} \begin{bmatrix} 1 \\ -\mathbf{w} \end{bmatrix} = \begin{bmatrix} J_{\min} \\ \mathbf{0} \end{bmatrix}$$

em que J_{\min} é o mínimo erro médio quadrático, \mathbf{w} é o filtro de Wiener, e \mathbf{A} é a matriz de correlação do vetor aumentado

$$\begin{bmatrix} d(n) \\ \mathbf{x}(n) \end{bmatrix}$$

em que $d(n)$ é o sinal desejado e $\mathbf{x}(n)$ é o sinal de entrada do filtro de Wiener.

- 3. (Cancelamento de ruído)** Em várias aplicações práticas há uma necessidade de cancelar ruído que foi adicionado a um sinal. Por exemplo, se estamos usando o telefone celular dentro de um ruído e o ruído do carro ou rádio é adicionado à mensagem que estamos tentando transmitir. A Figura 1 ilustra as situações de contaminação de ruído. Calcule o filtro de Wiener (filtro ótimo) de tal configuração em relação às estatísticas dos sinais envolvidos que você dispõe (conhece).




Figure 1: Esquema de cancelamento de ruído.

4. (Predição ótima) Seja um processo estocástico dado por

$$x(n) = s(n+a) + s(n-4a),$$

em que $S(n)$ é um processo estocástico WSS dado e a é uma constante.

Deseja-se filtrar o processo de tal forma obter-se um processo $D(s) = s(n-a)$, o qual também sabe-se que é um processo WSS. Suponha que o sinal $d(n)$ possua média nula e variância unitária.

- (a) Calcule o filtro, com dois coeficientes, que fornece a solução ótima em relação ao erro médio quadrático.
- (b) Calcule o preditor direto ótimo de passo unitário, com dois coeficientes, que fornece a solução ótima em relação ao erro médio quadrático.
- (c) Compare as soluções dos dois.

5. (Superfície de erro) Suponha que foram encontrados os seguintes coeficientes de autocorrelação: $r_x(0) = 1$ e $r_x(1) = 0$. Tais coeficientes foram obtidos de amostras corrompidas com ruído. Além disso, a variância do sinal desejado é $\sigma_d^2 = 24.40$ e o vetor de correlação cruzada é $\mathbf{p}_{xd} = [2 \ 4.5]^T$. Encontre:

- (a) O valor dos coeficientes do filtro de Wiener.
- (b) A superfície definida por $J(\mathbf{w})$. Faça um gráfico da mesma.

3 Lista 3: Algoritmos Recursivos

3.1 Algoritmo LMF

Organizar

Podemos inicialmente definir a função erro para esse filtro como

$$e(n) = d(n) - y(n), \quad (3.1)$$

$$e(n) = d(n) - \mathbf{w}^T(n)\mathbf{x}(n), \quad (3.2)$$

e para obtermos a nova expressão de recursão precisamos primeiro obter o equacionamento para o vetor gradiente instantâneo de $\mathbb{E}\{e^4(n)\}$. Isso pode ser prontamente obtido por meio do auxílio de uma derivação implícita

$$\nabla_{\mathbf{w}}\mathbb{E}\{e^4(n)\} = \frac{\partial\mathbb{E}\{e^4(n)\}}{\partial\mathbf{w}} = \mathbb{E}\left\{\frac{\partial e^4(n)}{\partial\mathbf{w}}\right\} = \mathbb{E}\left\{\frac{\partial e^4(n)}{\partial e(n)} \frac{\partial e(n)}{\partial\mathbf{w}}\right\}, \quad (3.3)$$

$$\nabla_{\mathbf{w}}\mathbb{E}\{e^4(n)\} = \mathbb{E}\left\{4e^3(n) \frac{\partial(d(n) - \mathbf{w}^T(n)\mathbf{x}(n))}{\partial\mathbf{w}}\right\} = \mathbb{E}\{4e^3(n)(0 - \mathbf{x}(n))\}, \quad (3.4)$$

$$\nabla_{\mathbf{w}}\mathbb{E}\{e^4(n)\} = -4\mathbb{E}\{e^3(n)\mathbf{x}(n)\}. \quad (3.5)$$

Desse modo, para que a minimização de $\mathbb{E}\{e^4(n)\}$ seja atingida precisamos garantir apenas que o vetor $\mathbf{x}(n)$ tenha entradas ortogonais ao vetor erro $e(n)$. Assim, é necessário que a seguinte equação seja verdade

$$\mathbb{E}\{e^3(n)\mathbf{x}(n)\} = 0, \quad (3.6)$$

$$\mathbb{E}\{(d(n) - \mathbf{w}^T(n)\mathbf{x}(n))^3\mathbf{x}(n)\} = 0, \quad (3.7)$$

onde é possível demonstrar que existe convergência em média para essa expressão se definirmos o passo de aprendizado no seguinte intervalo¹

$$1 < \mu < \frac{1}{6\sigma_z^2\lambda_{\max}}, \quad (3.8)$$

onde σ_z^2 é a variância do ruído presente e λ_{\max} é o maior autovalor da matriz de autocorrelação \mathbf{R}_x . Por fim, a partir dessas observações podemos escrever a expressão de recursão para o LMF utilizando a expressão padrão para o algoritmo do gradiente descendente²

$$\mathbf{w}(n+1) = \mathbf{w}(n) - \mu\mathbf{g}_w(n), \quad (3.9)$$

$$\mathbf{w}(n+1) = \mathbf{w}(n) + 4\mu e^3(n)\mathbf{x}(n), \quad (3.10)$$

onde sabemos que o erro é dado por $e(n) = d(n) - \mathbf{w}^T(n)\mathbf{x}(n)$.

¹A demonstração da propriedade foi extensivamente explicada no artigo *The Least Mean Square Fourth (LMF) Algorithm and Its Family* de 1984 por Eugene Walash e Bernard Widrow.

²Essa expressão é brevemente introduzida no livro texto da disciplina.

3.2 Algoritmo LMS

Organizar

1. a condição para convergência do algoritmo em média.

Solução:

A condição de convergência está diretamente associada com o erro nos coeficientes do filtro adaptativo para cada iteração. Desse modo, podemos iniciar o estudo desse tópico com a seguinte expressão que relaciona o erro dos coeficientes do filtro de uma iteração k para a solução ótima

$$\Delta \mathbf{w}(n) = \mathbf{w}(n) - \mathbf{w}_{\text{opt}}, \quad (3.11)$$

e assim podemos reescrever a função de recorrência do LMS do seguinte modo

$$\Delta \mathbf{w}(n+1) = \Delta \mathbf{w}(n) + 2\mu e(n) \mathbf{x}(n), \quad (3.12)$$

$$\Delta \mathbf{w}(n+1) = \Delta \mathbf{w}(n) + 2\mu \mathbf{x}(n) [\mathbf{x}^T(n) \mathbf{w}_{\text{opt}} + z(n) - \mathbf{x}^T(n) \mathbf{w}(n)], \quad (3.13)$$

$$\Delta \mathbf{w}(n+1) = \Delta \mathbf{w}(n) + 2\mu \mathbf{x}(n) [e_{\text{opt}}(n) - \mathbf{x}^T(n) \Delta \mathbf{w}(n)], \quad (3.14)$$

$$\Delta \mathbf{w}(n+1) = [\mathbf{I} - 2\mu \mathbf{x}(n) \mathbf{x}^T(n)] \Delta \mathbf{w}(n) + 2\mu e_{\text{opt}}(n) \mathbf{x}(n) \quad (3.15)$$

onde $z(n) \in \mathcal{N}(0, \sigma^2)$ e $e_{\text{opt}}(n) = z(n)$. Indicando que, para o caso ideal, teríamos que nos preocupar apenas com o erro introduzido pelas componentes ruidosas do sistema. Ademais, também utilizamos o fato de que $e(n) = e^T(n) = \mathbf{w}_{\text{opt}}^T \mathbf{x}(n) + z(n) - \mathbf{w}^T(n) \mathbf{x}(n) = \mathbf{x}^T(n) \mathbf{w}_{\text{opt}} + z(n) - \mathbf{x}^T(n) \mathbf{w}(n)$. Em sequência, podemos escrever o valor esperado para o erro como

$$\mathbb{E}\{\Delta \mathbf{w}(n+1)\} = \mathbb{E}\{[\mathbf{I} - 2\mu \mathbf{x}(n) \mathbf{x}^T(n)] \Delta \mathbf{w}(n) + 2\mu e_{\text{opt}}(n) \mathbf{x}(n)\}, \quad (3.16)$$

$$\mathbb{E}\{\Delta \mathbf{w}(n+1)\} = \mathbb{E}\{[\mathbf{I} - 2\mu \mathbf{x}(n) \mathbf{x}^T(n)] \Delta \mathbf{w}(n)\} + 2\mu \mathbb{E}\{e_{\text{opt}}(n) \mathbf{x}(n)\} \quad (3.17)$$

onde utilizamos a propriedade de linearidade do operador valor esperado. Ao assumirmos que $\mathbf{x}(n)$ é simultaneamente ortogonal aos elementos $e_{\text{opt}}(n)$ e $\Delta \mathbf{w}(n)$ podemos simplificar a expressão acima por

$$\mathbb{E}\{\Delta \mathbf{w}(n+1)\} = [\mathbf{I} - 2\mu \mathbb{E}\{\mathbf{x}(n) \mathbf{x}^T(n)\}] \mathbb{E}\{\Delta \mathbf{w}(n)\}, \quad (3.18)$$

$$\mathbb{E}\{\Delta \mathbf{w}(n+1)\} = (\mathbf{I} - 2\mu \mathbf{R}_x) \mathbb{E}\{\Delta \mathbf{w}(n)\}, \quad (3.19)$$

onde podemos utilizar a noção de que $\mathbb{E}\{\mathbf{I}\} = \mathbf{I}$ uma vez que temos um operador linear. Em continuidade, podemos supor que existe uma matriz \mathbf{Q} unitária que diagonaliza \mathbf{R}_x de tal modo que temos

$$\mathbb{E}\{\mathbf{Q}^T \Delta \mathbf{w}(n+1)\} = (\mathbf{I} - 2\mu \mathbf{Q}^T \mathbf{R}_x \mathbf{Q}) \mathbb{E}\{\Delta \mathbf{w}(n)\}, \quad (3.20)$$

$$\mathbb{E}\{\mathbf{Q}^T \Delta \mathbf{w}(n+1)\} = (\mathbf{I} - 2\mu \mathbf{Q}^T \mathbf{R}_x \mathbf{Q}) \mathbf{Q} \mathbf{Q}^T \mathbb{E}\{\Delta \mathbf{w}(n)\}, \quad (3.21)$$

$$\mathbb{E}\{\mathbf{Q}^T \Delta \mathbf{w}(n+1)\} = (\mathbf{I} - 2\mu \mathbf{Q}^T \mathbf{R}_x \mathbf{Q}) \mathbb{E}\{\mathbf{Q}^T \Delta \mathbf{w}(n)\}, \quad (3.22)$$

$$\mathbb{E}\{\Delta \mathbf{w}'(n+1)\} = (\mathbf{I} - 2\mu \mathbf{\Lambda}) \mathbb{E}\{\Delta \mathbf{w}'(n)\}. \quad (3.23)$$

Podemos, por fim, expandir os termos à esquerda e chegar na seguinte expressão para a análise do comportamento de convergência dos coeficientes de filtro

$$\mathbb{E}\{\Delta \mathbf{w}'(n+1)\} = (\mathbf{I} - 2\mu\mathbf{\Lambda})^{n+1} \mathbb{E}\{\Delta \mathbf{w}'(0)\}, \quad (3.24)$$

$$\mathbb{E}\{\Delta \mathbf{w}'(n+1)\} = \begin{bmatrix} (1 - 2\mu\lambda_1)^{n+1} & 0 & \cdots & 0 \\ 0 & (1 - 2\mu\lambda_2)^{n+1} & \cdots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & (1 - 2\mu\lambda_N)^{n+1} \end{bmatrix} \mathbb{E}\{\Delta \mathbf{w}'(0)\}, \quad (3.25)$$

onde temos que $\lambda_n \forall n \in \{1, \dots, N\}$ são os autovalores da matriz de autocorrelação. Portanto, vemos que para garantir a estabilidade da convergência é necessário apenas que o passo de aprendizado do algoritmo seja definido pela seguinte inequação

$$0 < \mu < \frac{1}{\lambda_{\max}}, \quad (3.26)$$

pois desse modo conseguimos garantir que os valores da diagonal irão tender a zero a medida que o número de iterações do algoritmo tende ao infinito. Ademais, é interessante ressaltar que a escolha do valor de μ deve também levar em consideração o espalhamento de energia da matriz de correlação. Dessa forma, se não há grande diferença entre os valores numéricos dos autovalores, então seria aconselhável escolher um passo de aprendizado muito menor do que aquele definido pelo limite superior da expressão obtida acima.

2. o erro em excesso em média quadrática.

Solução:

O erro em excesso é normalmente ocasionado pelos termos ruidosos presentes no gradiente, impedindo que os coeficientes convirjam de forma exata para a solução ótima. Podemos iniciar essa análise escrevendo a equação para o erro de estimação para um determinado instante n como se segue

$$e(n) = d(n) - \mathbf{w}_{\text{opt}}^T \mathbf{x}(n) - \Delta \mathbf{w}^T(n) \mathbf{x}(n), \quad (3.27)$$

$$e(n) = e_{\text{opt}}(n) - \Delta \mathbf{w}^T(n) \mathbf{x}(n), \quad (3.28)$$

onde o erro quadrático é expresso por

$$e^2(n) = e_{\text{opt}}^2(n) - 2e_{\text{opt}}(n)\Delta \mathbf{w}^T(n) \mathbf{x}(n) + \Delta \mathbf{w}^T(n) \mathbf{x}(n) \mathbf{x}^T(n) \Delta \mathbf{w}(n), \quad (3.29)$$

se definirmos o erro quadrático médio como $\xi(n) = \mathbb{E}\{e^2(n)\}$ e o erro ótimo, leia-se mínimo, como $\xi_{\min} = \mathbb{E}\{e_{\text{opt}}^2(n)\}$ então podemos escrever

$$\xi(n) = \xi_{\min} - 2\mathbb{E}\{e_{\text{opt}}(n)\Delta \mathbf{w}^T(n) \mathbf{x}(n)\} + \mathbb{E}\{\Delta \mathbf{w}^T(n) \mathbf{x}(n) \mathbf{x}^T(n) \Delta \mathbf{w}(n)\}, \quad (3.30)$$

considerando mais uma vez que \mathbf{x} é ortogonal ao $\Delta \mathbf{w}^T(n)$ e ao $e_{\text{opt}}(n)$, simultaneamente, podemos simplificar a expressão ainda mais

$$\xi(n) = \xi_{\min} - 2\mathbb{E}\{\Delta \mathbf{w}^T(n)\}\mathbb{E}\{e_{\text{opt}}(n)\mathbf{x}(n)\} + \mathbb{E}\{\Delta \mathbf{w}^T(n)\mathbf{x}(n)\mathbf{x}^T(n)\Delta \mathbf{w}(n)\}, \quad (3.31)$$

onde podemos utilizar a propriedade $\mathbb{E}\{\Delta \mathbf{w}^T(n)\mathbf{x}(n)\mathbf{x}^T(n)\Delta \mathbf{w}(n)\} = \text{tr}(\mathbb{E}\{\Delta \mathbf{w}^T(n)\mathbf{x}(n)\mathbf{x}^T(n)\Delta \mathbf{w}(n)\})$ uma vez que sabemos que o traço de um escalar é o próprio escalar. Sendo assim, utilizando a propriedade cíclica do operador traço escrevemos

$$\xi(n) = \xi_{\min} - 2\mathbb{E}\{\Delta \mathbf{w}^T(n)\}\mathbb{E}\{e_{\text{opt}}(n)\mathbf{x}(n)\} + \text{tr}(\mathbb{E}\{\Delta \mathbf{w}^T(n)\mathbf{x}(n)\mathbf{x}^T(n)\Delta \mathbf{w}(n)\}), \quad (3.32)$$

$$\xi(n) = \xi_{\min} - 2\mathbb{E}\{\Delta \mathbf{w}^T(n)\}\mathbb{E}\{e_{\text{opt}}(n)\mathbf{x}(n)\} + \mathbb{E}\{\text{tr}[\Delta \mathbf{w}^T(n)\mathbf{x}(n)\mathbf{x}^T(n)\Delta \mathbf{w}(n)]\}, \quad (3.33)$$

$$\xi(n) = \xi_{\min} - 2\mathbb{E}\{\Delta \mathbf{w}^T(n)\}\mathbb{E}\{e_{\text{opt}}(n)\mathbf{x}(n)\} + \mathbb{E}\{\text{tr}[\mathbf{x}(n)\mathbf{x}^T(n)\Delta \mathbf{w}(n)\Delta \mathbf{w}^T(n)]\}, \quad (3.34)$$

$$\xi(n) = \xi_{\min} + \mathbb{E}\{\text{tr}[\mathbf{x}(n)\mathbf{x}^T(n)\Delta \mathbf{w}(n)\Delta \mathbf{w}^T(n)]\}, \quad (3.35)$$

$$\xi(n) = \xi_{\min} + \text{tr}(\mathbb{E}\{\mathbf{x}(n)\mathbf{x}^T(n)\Delta \mathbf{w}(n)\Delta \mathbf{w}^T(n)\}), \quad (3.36)$$

$$\xi(n) = \xi_{\min} + \text{tr}(\mathbb{E}\{\mathbf{x}(n)\mathbf{x}^T(n)\}\mathbb{E}\{\Delta \mathbf{w}(n)\Delta \mathbf{w}^T(n)\}), \quad (3.37)$$

$$\xi(n) = \xi_{\min} + \text{tr}(\mathbf{R}_x \mathbb{E}\{\Delta \mathbf{w}(n)\Delta \mathbf{w}^T(n)\}), \quad (3.38)$$

$$\xi(n) = \xi_{\min} + \text{tr}(\mathbb{E}\{\mathbf{R}_x \Delta \mathbf{w}(n)\Delta \mathbf{w}^T(n)\}), \quad (3.39)$$

onde o processo justifica-se pela intercambialidade entre os operadores traço e valor esperado e pela ortogonalidade mencionada anteriormente. Em sequência podemos definir o erro em excesso por

$$\xi(n) - \xi_{\min} = \text{tr}(\mathbb{E}\{\mathbf{R}_x \Delta \mathbf{w}(n)\Delta \mathbf{w}^T(n)\}), \quad (3.40)$$

$$\Delta \xi(n) = \text{tr}(\mathbb{E}\{\mathbf{R}_x \Delta \mathbf{w}(n)\Delta \mathbf{w}^T(n)\}), \quad (3.41)$$

e adicionalmente, pela definição de uma transformação de similaridade onde garantimos que exista $\mathbf{Q}\mathbf{Q}^T = \mathbf{I}$ capaz de diagonalizar a matriz de autocorrelação, podemos reescrever a Equação (3.41) da seguinte forma

$$\Delta \xi(n) = \text{tr}(\mathbb{E}\{\mathbf{Q}\mathbf{Q}^T \mathbf{R}_x \mathbf{Q}\mathbf{Q}^T \Delta \mathbf{w}(n)\Delta \mathbf{w}^T(n)\mathbf{Q}\mathbf{Q}^T\}), \quad (3.42)$$

$$\Delta \xi(n) = \text{tr}(\mathbb{E}\{\mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^T \Delta \mathbf{w}(n)\Delta \mathbf{w}^T(n)\mathbf{Q}\mathbf{Q}^T\}), \quad (3.43)$$

$$\Delta \xi(n) = \text{tr}(\mathbb{E}\{\mathbf{Q}\mathbf{\Lambda}_{\text{cov}}[\Delta \mathbf{w}'(n)]\mathbf{Q}^T\}), \quad (3.44)$$

$$\Delta \xi(n) = \text{tr}(\mathbb{E}\{\mathbf{\Lambda}_{\text{cov}}[\Delta \mathbf{w}'(n)]\mathbf{Q}^T\mathbf{Q}\}), \quad (3.45)$$

$$\Delta \xi(n) = \text{tr}(\mathbb{E}\{\mathbf{\Lambda}_{\text{cov}}[\Delta \mathbf{w}'(n)]\}), \quad (3.46)$$

onde é sabido que $\text{cov}[\Delta \mathbf{w}(n)] = \mathbb{E}\{(\mathbf{w}(n) - \mathbf{w}_{\text{opt}})(\mathbf{w}(n) - \mathbf{w}_{\text{opt}})^T\}$ e $\Delta \mathbf{w}'(n) = \mathbf{Q}^T \Delta \mathbf{w}(n)\Delta \mathbf{w}^T(n)\mathbf{Q}$. Enfim, a partir das orientações presentes no livro texto da disciplina a respeito da matriz de covariância do vetor de erros é possível ainda escrever a Equação (3.46) como

$$\Delta \xi(n) = \sum_{i=1}^N \lambda_i v'_i(n) = \boldsymbol{\lambda}^T \mathbf{v}'(n), \quad (3.47)$$

onde λ é um vetor contendo todos os autovalores da matriz de autocorrelação e $\mathbf{v}(n)$ é um vetor que contém os elementos da diagonal de $\text{cov}[\Delta \mathbf{w}'(n)]$. Em suma, podemos expressar o i th elemento do vetor diagonal $\mathbf{v}'(n+1)$, seguindo orientações disponíveis no livro texto da disciplina, com o seguinte equacionamento

$$v'_i(n+1) = (1 - 4\mu\lambda_i + 8\mu^2\lambda_i^2)v'_i(n) + 4\mu^2\lambda_i \sum_{j=0}^N \lambda_j v'_j(n) + 4\mu^2\sigma_z^2\lambda_i. \quad (3.48)$$

Entretanto, se considerarmos que $v'_i(n+1) \approx v'_i(n)$ quando $n \rightarrow \infty$ podemos simplificar a expressão, além de que também podemos realizar uma operação de soma total dos parâmetros para obter o erro em excesso total

$$\begin{aligned} \sum_{i=1}^N v'_i(n) &= \sum_{i=1}^N (1 - 4\mu\lambda_i + 8\mu^2\lambda_i^2)v'_i(n) + 4\mu^2 \sum_{i=1}^N \lambda_i \sum_{j=0}^N \lambda_j v'_j(n) + 4\mu^2\sigma_z^2 \sum_{i=1}^N \lambda_i, \\ \sum_{i=1}^N v'_i(n) &= \sum_{i=1}^N v'_i(n) - 4\mu \sum_{i=1}^N \lambda_i v'_i(n) + 8\mu^2 \sum_{i=1}^N \lambda_i^2 v'_i(n) + 4\mu^2 \sum_{i=1}^N \lambda_i \sum_{j=0}^N \lambda_j v'_j(n) + 4\mu^2\sigma_z^2 \sum_{i=1}^N \lambda_i, \\ \sum_{i=1}^N v'_i(n) - \sum_{i=1}^N v'_i(n) + 4\mu \sum_{i=1}^N \lambda_i v'_i(n) - 4\mu^2 \sum_{i=1}^N \lambda_i \sum_{j=0}^N \lambda_j v'_j(n) &= 4\mu^2\sigma_z^2 \sum_{i=1}^N \lambda_i + 8\mu^2 \sum_{i=1}^N \lambda_i^2 v'_i(n), \\ 4\mu \sum_{j=1}^N \lambda_j v'_j(n) (1 - \mu \sum_{i=1}^N \lambda_i) &= 4\mu (\mu\sigma_z^2 \sum_{i=1}^N \lambda_i + 2\mu \sum_{i=1}^N \lambda_i^2 v'_i(n)), \\ \sum_{j=1}^N \lambda_j v'_j(n) &= \frac{\mu\sigma_z^2 \sum_{i=1}^N \lambda_i + 2\mu \sum_{i=1}^N \lambda_i^2 v'_i(n)}{1 - \mu \sum_{i=1}^N \lambda_i}, \\ \sum_{j=1}^N \lambda_j v'_j(n) &\approx \frac{\mu\sigma_z^2 \sum_{i=1}^N \lambda_i}{1 - \mu \sum_{i=1}^N \lambda_i}, \\ \sum_{j=1}^N \lambda_j v'_j(n) &= \frac{\mu\sigma_z^2 \text{tr}(\mathbf{R}_x)}{1 - \mu \text{tr}(\mathbf{R}_x)}, \end{aligned} \quad (3.49)$$

onde foi considerado que o termo $2\mu \sum_{i=1}^N \lambda_i^2 v'_i(n)$ apresenta contribuição insignificante para o valor absoluto do numerador. Entretanto, é mencionado no livro texto que tal aproximação é de prova complexa, mas que normalmente se verifica verdadeira para pequenos valores do passo de aprendizado μ . Portanto, o erro em excesso pode ser prontamente descrito pela expressão que se segue

$$\xi_{\text{excesso}} = \lim_{n \rightarrow \infty} \Delta \xi(n) \approx \frac{\mu\sigma_z^2 \text{tr}(\mathbf{R}_x)}{1 - \mu \text{tr}(\mathbf{R}_x)}. \quad (3.50)$$

Vale ainda expor que podemos considerar $1 - \mu \text{tr}(\mathbf{R}_x) \approx 1$ para valores muito pequenos de μ , obtendo assim uma versão aproximada para o erro em excesso dada por

$$\xi_{\text{excesso}} = \lim_{n \rightarrow \infty} \Delta \xi(n) \approx \mu\sigma_z^2 \text{tr}(\mathbf{R}_x). \quad (3.51)$$

3.3 Algoritmo LMS Normalizado

Organizar

Em acórdância com o livro texto da disciplina a expressão de atualização dos coeficientes de filtro para o algoritmo NLMS é dada por

$$\mathbf{w}(k+1) = \mathbf{w}(k) + \frac{\mu_{norm}}{\gamma + \mathbf{x}^T(k)\mathbf{x}(k)} \mathbf{e}(k)\mathbf{x}(k), \quad (3.52)$$

e considerando que o valor médio do passo de aprendizado aplicado na direção LMS $2\mathbf{e}(k)\mathbf{x}(k)$ é descrito por $\frac{\mu_{norm}}{2\text{tr}(\mathbf{R}_{xx})}$, então é possível chegar no seguinte limite superior para o valor de convergência se compararmos diretamente as fórmulas de atualização do LMS padrão com o LMS normalizado

$$0 < \frac{\mu_{norm}}{2\text{tr}(\mathbf{R}_{xx})} < \frac{1}{\text{tr}(\mathbf{R}_{xx})}, \quad (3.53)$$

$$0 < \mu_{norm} < 2, \quad (3.54)$$

3.4 Equalização de Canais

Organizar

3.4.1 Equalizado Ótimo e plano Z

Considerando um sinal gaussiano branco $x(n)$ a saída do canal pode ser prontamente obtida por

$$y(n) = x(n) + 1.6x(n-1), \quad (3.55)$$

e a matriz de autocorrelação será então dada por

$$\mathbf{R}_y = \begin{bmatrix} \mathbb{E}\{y(n)y^H(n)\} & \mathbb{E}\{y(n)y^H(n-1)\} \\ \mathbb{E}\{y(n-1)y^H(n)\} & \mathbb{E}\{y(n-1)y^H(n-1)\} \end{bmatrix}, \quad (3.56)$$

onde podemos calcular os valores teóricos para as correlações da seguinte forma se assumirmos que existe independência entre amostras distintas e que o sinal é média nula

$$\begin{aligned} \mathbb{E}\{y(n)y^H(n)\} &= \mathbb{E}\{\mathbf{x}^2(n) + 1.6\mathbf{x}(n)\mathbf{x}^H(n-1) + 1.6\mathbf{x}(n-1)\mathbf{x}^H(n) \\ &\quad + 2.56\mathbf{x}^2(n-1)\} = 3.56, \\ \mathbb{E}\{y(n)y^H(n-1)\} &= \mathbb{E}\{\mathbf{x}(n)\mathbf{x}^H(n-1) + 1.6\mathbf{x}(n)\mathbf{x}^H(n-2) + 1.6\mathbf{x}(n-1)\mathbf{x}^H(n-1) \\ &\quad + 2.56\mathbf{x}(n-1)\mathbf{x}^H(n-2)\} = 1.60, \\ \mathbb{E}\{y(n-1)y^H(n)\} &= \mathbb{E}\{\mathbf{x}(n-1)\mathbf{x}^H(n) + 1.6\mathbf{x}(n-1)\mathbf{x}^H(n-1) + 1.6\mathbf{x}(n-2)\mathbf{x}^H(n) \\ &\quad + 2.56\mathbf{x}(n-2)\mathbf{x}^H(n-1)\} = 1.60, \\ \mathbb{E}\{y(n-1)y^H(n-1)\} &= \mathbb{E}\{\mathbf{x}^2(n-1) + 1.6\mathbf{x}(n-1)\mathbf{x}^H(n-2) + 1.6\mathbf{x}(n-2)\mathbf{x}^H(n-1) \\ &\quad + 2.56\mathbf{x}(n-2)^2\} = 3.56, \end{aligned}$$

podendo assim descrever a matriz de autocorrelação teórica e sua inversa como

$$\mathbf{R}_y = \begin{bmatrix} 3.56 & 1.60 \\ 1.60 & 3.56 \end{bmatrix}, \quad (3.57)$$

$$\mathbf{R}_y^{-1} = \frac{1}{3.56^2 - 1.6^2} \begin{bmatrix} 3.56 & -1.60 \\ -1.60 & 3.56 \end{bmatrix} = \begin{bmatrix} 0.35 & -0.16 \\ -0.16 & 0.35 \end{bmatrix}. \quad (3.58)$$

Já o vetor de correlação cruzada teórico pode ser descrito por

$$\mathbf{p}_{yd} = \begin{bmatrix} \mathbb{E}\{y(n)d(n)\} \\ \mathbb{E}\{y(n-1)d(n)\} \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad (3.59)$$

pois queremos que o sinal de saída tenha a maior correlação possível com o sinal desejado de um mesmo instante mas continue sendo independente de um sinal de um instante temporal diferente. Desse modo, podemos obter o equalizador ótimo segundo o critério de Wiener como

$$\mathbf{w}_{\text{opt}} = \mathbf{R}_y^{-1} \mathbf{p}_{yd} = \begin{bmatrix} 0.35 \\ -0.16 \end{bmatrix}. \quad (3.60)$$

Por fim, abaixo segue o traçado para os zeros das funções de transferência tanto do canal quanto do filtro ótimo em azul e em vermelho, respectivamente.




Figura 3.1: Zeros do canal e do equalizador no plano-z.

3.4.2 Filtro de Erro de Predição Direta de Passo Unitário

De forma semelhante ao abordado anteriormente temos que o filtro de predição direta de passo unitário é dado por

$$\hat{x}(n) = \sum_{i=k}^{M+k-1} w_{f,i} x(n-i) = \sum_{i=1}^2 w_{f,i} x(n-i) = \mathbf{w}_f^T \mathbf{x}(n-1), \quad (3.61)$$

onde o erro quadrático médio é dado por

$$\mathbb{E}\{e^2(n)\} = \mathbb{E}\{(x(n) - \hat{x}(n))^2\} = \mathbf{r}_x(0) - 2\mathbf{w}_f^T \mathbf{r}_{x,f} + \mathbf{w}_f^T \mathbf{R}_x \mathbf{w}_f, \quad (3.62)$$

onde a solução ótima será dada por

$$\mathbf{w}_{f,\text{opt}} = \mathbf{R}_x^{-1} \mathbf{r}_{x,f}. \quad (3.63)$$

Teremos assim que a mesma matriz de autocorrelação e o vetor de correlação cruzada serão definidos por

$$\mathbf{R}_y = \begin{bmatrix} 3.56 & 1.60 \\ 1.60 & 3.56 \end{bmatrix}, \quad (3.64)$$

$$\mathbf{r}_{y,f} = \begin{bmatrix} r_y(1) \\ r_y(2) \end{bmatrix} = \begin{bmatrix} \mathbb{E}\{y(n)y(n-1)\} \\ \mathbb{E}\{y(n)y(n-2)\} \end{bmatrix} = \begin{bmatrix} 1.60 \\ 0 \end{bmatrix}. \quad (3.65)$$

Por essa razão temos

$$\mathbf{w}_{f,\text{opt}} = \begin{bmatrix} 0.35 & -0.16 \\ -0.16 & 0.35 \end{bmatrix} \begin{bmatrix} 1.60 \\ 0 \end{bmatrix} = \begin{bmatrix} 0.56 \\ -0.26 \end{bmatrix}. \quad (3.66)$$

Em seguida, podemos obter os zeros do filtro como

$$W(z) = 0.56 - 0.26z^{-1}, \quad (3.67)$$

$$0 = 0.56 - 0.26z^{-1}, \quad (3.68)$$

$$z = 0.45, \quad (3.69)$$

que é o mesmo zero do equalizador definido anteriormente.

3.4.3 Curvas de MSE e de Nível dos algoritmos

Ok

Como apresentado anteriormente, na seção 2, questão 5, o conceito de superfície de erro utilizado para traçar as curvas de nível e MSE é baseado respectivamente nas funções $J(w) = \sigma_d^2 - 2\mathbf{w}^\top \mathbf{p}_{\mathbf{x}d} + w^\top \mathbf{R}_X \mathbf{w}$ e $J(w) = \mathbb{E}\{e^2(n)\}$.




Figura 3.2: Resultados da implementação do algoritmo gradiente determinístico com $N = 1000$ amostras, filtro de ordem $M = 2$ e parâmetro $\mu = 10^{-2}$. **Superior:** Evolução da curva MSE. **Inferior:** Caminho percorrido até o ponto de convergência, i.e, filtro de Wiener.

As Figuras 3.2, 3.3, 3.4 e 3.5 apresentam o comportamento do erro quadrático médio (MSE) e as curvas de convergência sobre a superfície MSE para cada algoritmos implementado. A ordem de $M = 2$ foi utilizada para todos os filtros, conseqüentemente o vetor de pesos na atualização possui apenas 2 coeficientes atualizados por iteração. O desempenho médio de todos é muito semelhante, com certa vantagem para o NLMS.




Figura 3.3: Resultados da implementação do algoritmo Newton com $N = 1000$ amostras, filtro de ordem $M = 2$ e parâmetro $\mu = 0.5 \times 10^{-2}$. **Superior:** Evolução da curva MSE. **Inferior:** Caminho percorrido até o ponto de convergência, i.e, filtro de Wiener.




Figura 3.4: Resultados da implementação do algoritmo LMS com $N = 1000$ amostras, filtro de ordem $M = 2$ e parâmetro $\mu = 10^{-3}$. **Superior:** Evolução da curva MSE. **Inferior:** Caminho percorrido até o ponto de convergência, i.e, filtro de Wiener.




Figura 3.5: Resultados da implementação do algoritmo NLMS com $N = 1000$ amostras, filtro de ordem $M = 2$ e parâmetros $\mu = 0.5 \times 10^{-1}$ and $\gamma = 0.5$. **Superior:** Evolução da curva MSE. **Inferior:** Caminho percorrido até o ponto de convergência, i.e, filtro de Wiener.

Para os métodos determinísticos, é possível observar que há convergência organizada e suave. Isso é esperado, dado que o algoritmo utiliza o conhecimento dos coeficientes ideais do filtro. Enquanto para os métodos estocásticos, é visível algumas regiões de desordem na convergência, isso é dado como consequência da utilização das aproximações estatísticas instantâneas do sinal para o cálculo dos coeficientes. Ao comparar o LMS e sua versão normalizada, o primeiro apresenta uma maior estabilidade de convergência, enquanto o segundo apresentar uma nuvem de pontos bem menos densa em torno da solução de Wiener, além de pontos que aparentemente se afastam da solução, consequência das iterações iniciais.

3.4.4 Número de condicionamento

O número de condicionamento pode ser prontamente obtido pela expressão

$$\mathbb{C}(\mathbf{R}_x) = \frac{\lambda_{\max}}{\lambda_{\min}}, \quad (3.70)$$

onde λ_{\max} e λ_{\min} são os autovalores máximo e mínimo da matriz de autocorrelação, respectivamente. Por meio de um software matemático foi possível obter os seguintes autovalores para a matriz de autocorrelação teórica

$$\mathbb{C}(\mathbf{R}_x) = \frac{5.16}{1.96} = 2.63, \quad (3.71)$$

onde talvez seja importante ressaltar que também poderíamos ter obtido os autovalores resolvendo a equação do polinômio característico da matriz de autocorrelação que é dada por

$$\lambda^2 - 7.12\lambda + 10.11 = 0. \quad (3.72)$$

3.4.5 Modelo de canal para número de condicionamento menor/maior que 5

Comente os resultados.

Inicialmente podemos escrever a matriz de correlação contabilizando a contribuição dos coeficientes do canal para os elementos individuais

$$\mathbf{R}_y = \begin{bmatrix} a_0 + a_1^2 & a_1 \\ a_1 & a_0 + a_1^2 \end{bmatrix}, \quad (3.73)$$

onde a função de transferência do canal seria dada por $H(z) = a_0 + a_1 z^{-1}$. A partir dessa matriz de autocorrelação genérica podemos então definir o seguinte polinômio característico

$$(\lambda - a_0 + a_1^2)^2 - a_1^2 = 0, \quad (3.74)$$

$$\underbrace{\lambda^2 - 2(a_0 + a_1^2)\lambda + (a_0 + a_1^2)^2 - a_1^2}_b = 0, \quad (3.75)$$

$$\lambda^2 + b\lambda + c = 0, \quad (3.76)$$

onde sabemos que a solução é facilmente obtida pela fórmula de Bháskara. A partir disso podemos definir o número de condicionamento como

$$\mathbb{C}(\mathbf{R}_x) = \frac{\lambda_{\max}}{\lambda_{\min}}, \quad (3.77)$$

$$\mathbb{C}(\mathbf{R}_x) = \frac{-b + \sqrt{b^2 - 4c}}{-b - \sqrt{b^2 - 4c}}, \quad (3.78)$$

$$\mathbb{C}(\mathbf{R}_x) = \frac{2(a_0 + a_1^2) + \sqrt{4(a_0 + a_1^2)^2 - 4(a_0 + a_1^2)^2 + 4a_1^2}}{2(a_0 + a_1^2) - \sqrt{4(a_0 + a_1^2)^2 - 4(a_0 + a_1^2)^2 + 4a_1^2}}, \quad (3.79)$$

$$\mathbb{C}(\mathbf{R}_x) = \frac{2(a_0 + a_1^2) + 2a_1}{2(a_0 + a_1^2) - 2a_1}, \quad (3.80)$$

$$\mathbb{C}(\mathbf{R}_x) = \frac{a_0 + a_1^2 + a_1}{a_0 + a_1^2 - a_1}, \quad (3.81)$$

assim temos agora uma fórmula para o número de condicionamento da matriz de autocorrelação com base nos coeficientes de canal. A partir disso basta que as seguintes inequações sejam atendidas para que obtenhamos um número de condicionamento maior ou menor do que o requerido

$$a_0 + a_1^2 + a_1 \geq 5(a_0 + a_1^2 - a_1), \quad (3.82)$$

$$a_0 + a_1^2 + a_1 \leq 5(a_0 + a_1^2 - a_1). \quad (3.83)$$

3.5 Identificação de Sistemas

Organizar

$$H(z) = \frac{1 - z^{-12}}{1 - z^{-1}} \quad (3.84)$$

1. Calcule o limite superior para μ (ou seja μ_{\max}) para garantir a estabilidade do algoritmo.

Solução:

Para garantirmos a estabilidade do algoritmo precisamos apenas obter o valor numérico do maior autovalor definido pela matriz de autocorrelação do problema. Desse modo, podemos simplificar a função de transferência por meio da seguinte manipulação algébrica

$$\begin{aligned} H(z) &= \frac{1 - z^{-12}}{1 - z^{-1}}, \\ H(z) &= \frac{(1 - z^{-1})(1 + z^{-1} + z^{-2} + z^{-3} + z^{-4} + z^{-5} + z^{-6} + z^{-7} + z^{-8} + z^{-9} + z^{-10} + z^{-11})}{1 - z^{-1}}, \\ H(z) &= 1 + z^{-1} + z^{-2} + z^{-3} + z^{-4} + z^{-5} + z^{-6} + z^{-7} + z^{-8} + z^{-9} + z^{-10} + z^{-11}, \end{aligned}$$

e tomando a transformada z inversa da função de transferência chega-se a seguinte saída de um sinal transmitido por esse canal

$$\begin{aligned} y(n) &= x(n) + x(n-1) + x(n-2) + x(n-3) + x(n-4) + x(n-5) + x(n-6) + x(n-7) \\ &\quad + x(n-8) + x(n-9) + x(n-10) - x(n-11), \end{aligned}$$

Em sequência é possível utilizar um software matemático para obter uma estimação para a matriz de autocorrelação




Figura 3.6: Matriz de autocorrelação estimada após 10000 realizações para retirada do comportamento médio

onde a análise de autovalores de \mathbf{R}_{xx} resulta no seguinte intervalo de convergência para o passo de aprendizado

$$0 < \mu < \frac{1}{\lambda_{\max}} = \frac{1}{97} \approx 0.01, \quad (3.85)$$

e assim $\mu_{\max} \approx 0.01$.

2. Execute o algoritmo para $\frac{\mu_{\max}}{2}$, $\frac{\mu_{\max}}{10}$ e $\frac{\mu_{\max}}{50}$. Comente sobre o comportamento da convergência de cada caso.

Solução:

Nas Figuras 3.7, 3.8 e 3.9 podemos verificar o comportamento da convergência do algoritmo para esse problema. A princípio é possível confirmar que existe uma diminuta piora quanto ao desempenho dos algoritmos a medida que o passo de aprendizado desce. Isso pode ser explicado pois a medida que μ fica menor a flexibilidade de adaptação do algoritmo é reduzida. Assim, para passos de aprendizado muito pequenos é mais difícil para o filtro conseguir acompanhar as mudanças no canal provocadas pelo impacto de componentes ruidosas e pela resposta em frequência do canal.




Figura 3.7: Amostras = 1000, $M = 15$, $\mu = \frac{\mu_{\max}}{2}$




Figura 3.8: Amostras = 1000, $M = 15$, $\mu = \frac{\mu_{\max}}{10}$




Figura 3.9: Amostras = 1000, $M = 15$, $\mu = \frac{\mu_{\max}}{50}$

3. Meça o desajuste (misadjustment) em cada exemplo e comparar com os resultados obtidos pela solução teórica (Eq. (3.50) do livro texto)

Solução:

O desajuste pode ser aproximado por

$$M = \frac{\xi_{\text{excesso}}}{\xi_{\text{min}}} \approx \frac{\mu \text{tr}(\mathbf{R}_x)}{1 - \mu \text{tr}(\mathbf{R}_x)}, \quad (3.86)$$

e a partir dessa expressão foi possível obter a seguinte tabela

	Empírico	Téorico
$\frac{\mu_{\max}}{2}$	-1.3865	-1.3846
$\frac{\mu_{\max}}{10}$	+2.5392	+2.5714
$\frac{\mu_{\max}}{50}$	+0.1675	+0.1682

Os resultados foram obtidos por uso de software matemático e os códigos estão disponíveis juntamente com este relatório.

4. Mostre o gráfico da resposta em frequência do filtro FIR em qualquer uma das iterações após a convergência ser obtida e compare com o sistema desconhecido.

Solução:

A resposta em frequência do filtro está disponível nas Figuras 3.10, 3.11 e 3.13 para os casos $\frac{\mu_{\max}}{2}$, $\frac{\mu_{\max}}{10}$ e $\frac{\mu_{\max}}{50}$, respectivamente. É possível ver que a resposta em frequência do filtro tende a se aproximar da resposta em frequência do sistema quanto maior o passo de aprendizado, pois quanto maior μ mais facilidade tem o filtro em acompanhar as variações do canal. No caso extremo onde temos um passo de aprendizado $\frac{\mu_{\max}}{50}$ é possível verificar que a resposta em frequência do filtro é uma versão consideravelmente amortecida da resposta original do canal. Ademais, na Figura 3.12 vemos a evolução temporal do filtro para as primeiras 100 amostras quando temos a resposta em frequência dada na Figura 3.10.




Figura 3.10: Amostras = 1000, $M = 15$, $\mu = \frac{\mu_{\max}}{2}$




Figura 3.11: Amostras = 1000, $M = 15$, $\mu = \frac{\mu_{\max}}{10}$




Figura 3.12: Amostras = 1000, $M = 15$, $\mu = \frac{\mu_{\max}}{50}$




Figura 3.13: Amostras = 1000, $M = 15$, $\mu = \frac{\mu_{\max}}{2}$

3.6 Equalização Adaptativa

Organizar

$$H(z) = 0.5 + 1.2z^{-1} + 1.5z^{-2} + z^{-3}, \quad (3.87)$$

e deseja-se projetar um equalizador para o mesmo. A estrutura do equalizador é mostrada na Figura abaixo. Os símbolos $s(n)$ são transmitidos através de um canal e corrompidos por ruído aditivo gaussiano branco complexo $v(n)$. O sinal recebido $x(n)$ é processado pelo equalizador FIR para gerar estimativas $\tilde{s}(n - \delta)$, as quais são passadas por um dispositivo decisor gerando símbolos $\hat{s}(n - \delta)$. O equalizador possui dois modos de operação: um modo de treinamento durante o qual uma versão atrasada e replicada da sequência de entrada é usada como o sinal de referência (desejado) e um modo dirigido por decisão no qual a saída do dispositivo de decisão substitui a sequência de referência. O sinal de entrada $s(n)$ é escolhido de uma constelação QAM (por exemplo, 4-QAM, 16-QAM, 64-QAM ou 256-QAM).

1. Faça um programa que treine o filtro adaptativo com 500 símbolos de uma constelação 4-QAM, seguindo de uma operação dirigida por decisão de 5000 símbolos de uma constelação 16-QAM. Escolha a variância do ruído σ_v^2 de maneira que ela promova uma relação sinal ruído de 30 db na entrada do equalizador. Note que os símbolos escolhidos não têm variância unitária. Por esta razão, a a variância do ruído necessita ser ajustada adequadamente para cada uma das diferentes modulações (constelações) QAM para fornecer o nível de SNR desejado. Escolha $\delta = 15$ e o comprimento do equalizador $M = 15$. Mostre os gráficos da evolução temporal de $s(n)$, $x(n)$ e $\tilde{s}(n - \delta)$. Use o LMS-normalizado com um fator de passo de $\mu = 0.4$.

Solução:

Os resultados estão nas Figuras 3.14 e 3.15. A evolução temporal do MSE apresenta comportamento similar aos resultados apresentados anteriormente com o MSE possuindo uma grande variação mesmo após a convergência. Por fim, também é possível ver na figura seguinte o impacto no filtro na filtragem de um sinal modulado por 16-QAM. É visível que a estimação conseguiu separar o sinal transmitido em diferentes regiões de decisão e assim seria necessário ao fim desse processo passar esse sinal filtrado por um decisor para que fosse obtida uma aproximação do sinal originalmente transmitido. Ademais, foi implementado um simples processo de aprendizado utilizando algumas amostras de sinais 4-QAM para o treinamento do filtro com o objetivo de facilitar ou acelerar a convergência quando o sinal 16-QAM fosse filtrado.

Além disso, na Figura 3.16 é possível acompanhar a evolução temporal do sinal filtrado e do sinal original para dois momentos distintos. No primeiro, temos a adaptação do filtro para as primeiras 100 amostras e previsivelmente confirmamos que o filtro possui ainda dificuldades em acompanhar o canal nas primeiras amostras. Já no segundo momento temos as últimas 100 amostras do filtro e podemos entender a partir disso que o filtro agora tem capacidade de acompanhar o canal de forma mais eficiente, embora ainda existam momentos onde erros ocorrem. Esses erros podem ser ocasionados pelas interferências ruidosas que provocam erros de detecção na hora de avaliar as constelações aproximadas que saem do processo de filtragem.




Figura 3.14: Amostras = 5000, $M = 15$, $\mu = 0.4$




Figura 3.15: Amostras = 5000, $M = 15$, $\mu = 0.4$




Figura 3.16: Amostras = 5000, $M = 15$, $\mu = 0.4$

2. Para os mesmos parâmetros do item (a), plote e compare os gráficos de evolução que seriam resultante se o equalizador fosse treinado com 150, 300 e 500 iterações. Use o LMS com um $\mu = 0.001$.

Solução:

O resultado está na Figura 3.17. Particularmente não pude distinguir notáveis diferenças de desempenho ao considerar diferentes tamanhos de sequências de treinamento.




Figura 3.17: Amostras = 5000, $M = 15$, $\mu = 0.001$

3. Assuma agora que os dados transmitidos foram gerados de uma constelação 256-QAM ao invés de 16-QAM. Plote os gráficos da evolução do sinal na saída do equalizador quando treinado usando o LMS-normalizado e 500 símbolos de treinamento.

Solução:

Os resultados estão nas Figuras 3.18 e 3.19. É possível verificar na primeira figura que a evolução do MSE aconteceu apesar de uma considerável variação ao final da convergência. Já em relação a figura seguinte, onde transmitimos um sinal 256-QAM e utilizamos um filtro treinado por um sinal 4-QAM, é possível verificar que inicialmente o filtro demonstrou dificuldade em acompanhar a evolução do canal. Por fim, em um segundo momento é apresentado a evolução temporal considerando as ultimas amostras do sinal e aqui podemos visualizar que, embora ainda existam uma quantidade considerável de erros por se tratar de uma modulação de ordem elevada, o filtro consegue se aproximar com um pouco mais de facilidade do sinal original.

Adicionalmente, para termos uma melhor interpretação do desempenho desse filtro seria necessário utilizar uma métrica como a SER ou BER e comparar o impacto de diferentes modulações no desempenho do algoritmo de filtragem. Isso se deve pois quando utilizamos um decisor o símbolo filtrado pode ser alocado para uma região da constelação da modulação a qual não pertence. Entretanto, tais erros de decisão so são aparente quando utilizamos uma métrica capaz de capturar tal fenômeno.

4. Gerar as curvas de taxa de erro de símbolo (SER, do inglês Symbol Error Rate) versus SNR na entrada do equalizador para símbolos de constelações 4, 16, 64 e 256-QAM. Faça SNR variar de 5dB a 30dB.

Solução:

Os resultados estão na Figura 3.20. Assim, podemos analisar o real desempenho do filtro quando associado a um equalizador que desconhece o sinal verdadeiro. É possível




Figura 3.18: Amostras = 5000, $M = 15$, $\mu = 0.4$




Figura 3.19: Amostras = 5000, $M = 15$, $\mu = 0.4$

verificar que a medida que a ordem de modulação aumenta o desempenho sofre uma considerável piora. Existem duas principais razões para explicar esse comportamento. A primeira vem justamente do tamanho das constelações digitais que a medida que a ordem aumenta tem uma menor região de decisão associada aos seus símbolos. Desse modo, o sinal transmitido fica sujeito a interferências de componentes ruidosas do canal pois as divisórias entre as diversas regiões de decisão dos símbolos da modulação ficam menores e erros de decisão irão acontecer com maior frequência. A segunda razão poderia ser explicada pelo fato do filtro ter sido inicialmente treinado utilizando símbolos modulados com 4-QAM, mas provavelmente isso é insuficiente quando a ordem de modulação do sinal transmitido cresce. Ademais, vale ressaltar que não houve erros para $\text{SNR} = 30$ dB quando se transmitiu sinais 4-QAM, entretanto como foram utilizados apenas 1000 realizações de Monte Carlo não foi possível capturar erros para esse ponto específico de SNR.




Figura 3.20: Amostras = 5000, $M = 15$, $\mu = 0.4$



Filtragem Adaptativa - TIP 7188

Prof. Dr. Charles Casimiro Cavalcante
Prof. Dr. Guilherme de Alencar Barreto

Período: 2022.2

Lista de Exercícios No. 3: Algoritmos Recursivos

- 1. (Algoritmo LMF)** Deseja-se minimizar a função objetivo $E\{e^4(n)\}$ utilizando-se um algoritmo do gradiente estocástico do tipo LMS. O algoritmo resultando é chamado de algoritmo *least mean fourth* (LMF). Derive tal algoritmo. Derive também o filtro ótimo para tal critério e compare as soluções.
- 2. (Algoritmo LMS)** Considere o uso de um a sequência de ruído branco com média nula e variância σ^2 como entrada do algoritmo LMS. Avalie
 - (a) a condição para convergência do algoritmo em média quadrática;
 - (b) o erro em excesso em média quadrática.
- 3. (Algoritmo LMS Normalizado)** Avalie a questão anterior para o caso do algoritmo LMS-Normalizado. Compare os dois casos.
- 4. (Equalização de canais)** Considere um sinal branco gaussiano de variância unitária transmitido por um canal de comunicação de função de transferência $H(z) = 1 + 1.6z^{-1}$. Para compensar este canal utiliza-se um equalizador dado por $W(z) = w_0 + w_1z^{-1}$.
 - (a) Forneça o equalizador ótimo segundo o critério de Wiener. Esboce a posição dos zeros do canal e do equalizador no plano Z .
 - (b) Obtenha o filtro de erro de predição direta de passo unitário, correspondente ao sinal à saída do canal. Calcule os zeros deste filtro e compare com os do equalizador.
 - (c) Obtenha as trajetórias sobre as curvas de nível, tendo condições iniciais nulas para os coeficientes do equalizador, para os seguintes algoritmos
 - (a) Gradiente determinístico;
 - (b) Algoritmo de Newton;
 - (c) LMS;
 - (d) LMS-normalizado;
 - (d) Obtenha também a evolução do erro quadrático médio para cada um dos algoritmos anteriores.
 - (e) Qual o número de condicionamento para o problema em questão?
 - (f) Qual deveria ser o canal para que o número de condicionamento fosse menor/maior que 5? Comente os resultados.
- 5. (Identificação de sistemas)** Utilize o algoritmo LMS para identificar um sistema com a função de transferência dada abaixo.

$$H(z) = \frac{1 - z^{-12}}{1 - z^{-1}}$$

O sinal de entrada é um ruído branco distribuído uniformemente com variância $\sigma_x^2 = 1$, e o ruído de medida é assumido gaussiano branco descorrelacionado da entrada e com variância de entrada $\sigma_v^2 = 10^{-3}$. O filtro adaptativo tem 12 coeficientes.

- (a) Calcule o limite superior para μ (ou seja μ_{\max}) para garantir a estabilidade do algoritmo.

- Execute o algoritmo para $\frac{\mu_{\max}}{2}$, $\frac{\mu_{\max}}{10}$ e $\frac{\mu_{\max}}{50}$. Comente sobre o comportamento da convergência de cada caso.
- Meça o desajuste (*misadjustment*) em cada exemplo e comparar com os resultados obtidos pela solução teórica (Eq. (3.50) do livro texto)
- Mostre o gráfico da resposta em frequência do filtro FIR em qualquer uma das iterações após a convergência ser obtida e compare com o sistema desconhecido.

6. (Equalização adaptativa) Seja o canal de comunicações dado por

$$H(z) = 0.5 + 1.2z^{-1} + 1.5z^{-2} - z^{-3}$$

e deseja-se projetar um equalizador para o mesmo. A estrutura do equalizador é mostrada na Figura 1. Os símbolos $s(n)$ são transmitidos através de um canal e corrompidos por ruído aditivo gaussiano branco complexo $v(n)$. O sinal recebido $x(n)$ é processado pelo equalizador FIR para gerar estimativas $\hat{s}(n - \delta)$, as quais são passadas por um dispositivo decisor gerando símbolos $\hat{s}(n - \delta)$. O equalizador possui dois modos de operação: um modo de treinamento durante o qual uma versão atrasada e replicada da sequência de entrada é usada como o sinal de referência (desejado) e um modo dirigido por decisão no qual a saída do dispositivo de decisão substitui a sequência de referência. O sinal de entrada $s(n)$ é escolhido de uma constelação QAM (por exemplo, 4-QAM, 16-QAM, 64-QAM ou 256-QAM).




Figure 1: Equalizador linear adaptativo operando em dois modos: modo de treinamento e modo dirigido por decisão.

- Faça um programa que treine o filtro adaptativo com 500 símbolos de uma constelação 4-QAM, seguindo de uma operação dirigida por decisão de 5000 símbolos de uma constelação 16-QAM. Escolha a variância do ruído σ_v^2 de maneira que ela promova uma relação sinal ruído de 30 db na entrada do equalizador. Note que os símbolos escolhidos não têm variância unitária. Por esta razão, a a variância do ruído necessita ser ajustada adequadamente para cada uma das diferentes modulações (constelações) QAM para fornecer o nível de SNR desejado. Escolha $\delta = 15$ e o comprimento do equalizador $M = 15$. Mostre os gráficos da evolução temporal de $s(n)$, $x(n)$ e $\hat{s}(n - \delta)$. Use o LMS-normalizado com um fator de passo de $\mu = 0.4$.
- Para os mesmos parâmetros do item (a), plote e compare os gráficos de evolução que seriam resultante se o equalizador fosse treinado com 150, 300 e 500 iterações. Use o LMS com um $\mu = 0.001$.
- Assuma agora que os dados transmitidos foram gerados de uma constelação 256-QAM ao invés de 16-QAM. Plote os gráficos da evolução do sinal na saída do equalizador quando treinado usando o LMS-normalizado e 500 símbolos de treinamento.
- Gerar as curvas de taxa de erro de símbolo (SER, do inglês *Symbol Error Rate*) versus SNR na entrada do equalizador para símbolos de constelações 4, 16, 64 e 256-QAM. Faça SNR variar de 5 dB a 30 dB.

4 Lista 4: Método dos Mínimos Quadrados

4.1 Algoritmo RLS

Organizar

Iterations	w_0	w_1	w_2
i = 1	1.0000	0.000000	0.000000
i = 2	1.0703	0.094579	0.087444
i = 3	0.63832	0.67774	-0.22783
i = 4	0.25922	0.43298	0.28991
i = 5	0.26607	0.4316	0.28539
i = 6	0.29342	0.40148	0.30207
i = 7	0.29611	0.40434	0.29579
i = 8	0.3016	0.42552	0.27103
i = 9	0.41718	0.35248	0.23766
i = 10	0.38104	0.34597	0.29742




Figura 4.1: Primeiro coeficiente livre para adaptação com Amostras = 100, $M = 2$, $\lambda = 0.98$

Na tabela acima foram disponibilizados os coeficientes de filtro para as 10 primeiras iterações como foi pedido. A tabela e o algoritmo de filtragem foram implementados utilizando software matemático e os códigos foram disponibilizados junto com o relatório. É possível observar nessas primeiras 10 iterações a convergência dos coeficientes de filtro rumo a estabilidade que poderia ser observada se mais algumas iterações fossem disponibilizadas na tabela.

Ademais, decidi apresentar o traçado do sinal senoidal transmitido comparando-o diretamente com o sinal filtrado na Figura 4.1. É possível conferir que o sinal filtrado começa com uma amplitude bastante distante do sinal verdadeiro, mas a medida que mais amostras são utilizadas para a adaptação do sinal a resposta em amplitude do sinal filtrado se aproxima do comportamento ideal. Existem algumas oscilações ao longo das 100 amostras, mas sem mudanças abruptas. É necessário apenas chamar atenção para o comportamento repentino apresentado no final do processo que é uma consequência da minha implementação para o RLS. Considero que o filtro inicia com sua janela totalmente preenchida o que por consequência induz a interrupção do algoritmo quando a janela chega a sua última seção onde está totalmente preenchida.

Por fim, na tabela abaixo e na Figura 4.2 apresento os resultados para o cenário onde o primeiro coeficiente do filtro RLS é mantido fixo em 1. Podemos ver de mais imediato que os coeficientes que estão livres para a adaptação apresentam considerável instabilidade quando comparados com o cenário onde os três coeficientes estão livres. Consequentemente, o filtro tem uma dificuldade bem maior em acompanhar as mudanças do sinal de referência quando comparamos com o resultado da Figura 4.1.

Iterations	w_0	w_1	w_2
i = 1	1	0	0
i = 2	1	-0.043423	-0.044953
i = 3	1	-0.031108	-0.038147
i = 4	1	-0.030954	-0.037966
i = 5	1	-0.021256	-0.027157
i = 6	1	-0.016635	-0.01361
i = 7	1	-0.0091408	-0.0052317
i = 8	1	-0.011328	-0.0066525
i = 9	1	-0.017649	-0.00074347
i = 10	1	-0.0095932	-0.012379




Figura 4.2: Primeiro coeficiente fixo com Amostras = 100, $M = 2$, $\lambda = 0.98$

4.2 Erro de Estimação a Priori

Organizar

$$\epsilon(n) = d(n) - \mathbf{w}^H(n-1)\mathbf{x}(n), \quad (4.1)$$

em que $d(n)$ é a resposta desejada, $\mathbf{x}(n)$ é o vetor de entrada do filtro e $\mathbf{w}(n-1)$ é a estimativa anterior do vetor de coeficientes do filtro. Seja $e(n)$ o erro de estimação a posteriori

$$e(n) = d(n) - \mathbf{w}^H(n)\mathbf{x}(n), \quad (4.2)$$

em que $\mathbf{w}(n)$ é a estimativa atual do vetor de coeficientes do filtro. Para dados complexos ambos $\epsilon(n)$ e $e(n)$ são de valores complexos. Mostre que o produto $\epsilon(n)e^*(n)$ é sempre de valor real.

Solução:

Primeiramente é necessário reescrever $e(n)$ em termos de $\epsilon(n)$. Inicialmente podemos escrever os coeficientes de filtro do instante n , utilizando o erro a priori, da seguinte forma

$$\mathbf{w}(n) = \mathbf{w}(n-1) + \epsilon(n)\mathbf{S}_D(n)\mathbf{x}(n), \quad (4.3)$$

e em seguida substituímos a expressão acima na definição do erro de estimação instantâneo e obtemos

$$e(n) = d(n) - \mathbf{w}^H(n)\mathbf{x}(n), \quad (4.4)$$

$$e(n) = d(n) - \mathbf{x}^H(n)\mathbf{w}(n), \quad (4.5)$$

$$e(n) = d(n) - \mathbf{x}^H(n) [\mathbf{w}(n-1) + \epsilon(n)\mathbf{S}_D(n)\mathbf{x}(n)], \quad (4.6)$$

$$e(n) = d(n) - \mathbf{x}^H(n)\mathbf{w}(n-1) - \mathbf{x}^H(n)\epsilon(n)\mathbf{S}_D(n)\mathbf{x}(n), \quad (4.7)$$

$$e(n) = \underbrace{d(n) - \mathbf{x}^H(n)\mathbf{w}(n-1)}_{\epsilon(n)} - \epsilon(n)\mathbf{x}^H(n)\mathbf{S}_D(n)\mathbf{x}(n), \quad (4.8)$$

$$e(n) = \epsilon(n) - \epsilon(n)\mathbf{x}^H(n)\mathbf{S}_D(n)\mathbf{x}(n), \quad (4.9)$$

$$(4.10)$$

e em sequência desenvolvemos o conjugado de $e(n)$ do seguinte modo

$$e^*(n) = \epsilon^*(n) - \epsilon^*(n)\mathbf{x}^H(n)\mathbf{S}_D(n)\mathbf{x}(n), \quad (4.11)$$

onde o termo $\mathbf{x}^H(n)\mathbf{S}_D(n)\mathbf{x}(n)$ é a distância de Mahalanobis que será sempre real e positiva. Desse modo, ao fazermos $\epsilon(n)e^*(n)$ obtemos

$$\epsilon(n)e^*(n) = \epsilon(n) [\epsilon^*(n) - \epsilon^*(n)\mathbf{x}^H(n)\mathbf{S}_D(n)\mathbf{x}(n)], \quad (4.12)$$

$$\epsilon(n)e^*(n) = \epsilon(n)\epsilon^*(n) - \epsilon(n)\epsilon^*(n)\mathbf{x}^H(n)\mathbf{S}_D(n)\mathbf{x}(n), \quad (4.13)$$

$$\epsilon(n)e^*(n) = \epsilon(n)\epsilon^*(n) (1 - \mathbf{x}^H(n)\mathbf{S}_D(n)\mathbf{x}(n)). \quad (4.14)$$

Dessa forma, sabemos que o termos $(1 - \mathbf{x}^H(n)\mathbf{S}_D(n)\mathbf{x}(n))$ será sempre real, embora nem sempre positivo, e $\epsilon(n)\epsilon^*(n)$ pode simplesmente ser visto como uma norma dada por $\|\epsilon(n)\|^2 = \epsilon(n)\epsilon^*(n)$, demonstrando assim que sempre teremos um valor real para $\epsilon(n)e^*(n)$.

4.3 Preditor Adaptativo

Organizar

Os resultados podem ser encontrados nas Figuras 4.3 - 4.10. Nas figuras 4.3 e 4.4 temos a evolução dos coeficientes de filtro e do MSE para o RLS com fator de esquecimento $\lambda = 0.9$, SNR = 3 dB e ordens $M = 2$ e $M = 3$, respectivamente. Nesses cenários podemos ver que o RLS não atingiu a estabilidade em seus coeficientes de filtro embora tenha apresentado um comportamento MSE sem grandes variações de magnitude. Ademais, no segundo cenário é possível verificar maior estabilidade na evolução do MSE graças ao incremento na ordem do RLS. Em sequência, nas Figuras 4.5 e 4.6 temos dois cenários similares, mas agora com um fator de conhecimento igual a $\lambda = 0.99$. Diferentemente dos dois primeiros cenários agora é possível verificar que o RLS atingiu estabilidade em seus coeficientes de filtro, além de um

melhor desempenho na evolução do MSE do que nos casos anteriores. Isso se deve pois, diferente do que ocorre com o passo de aprendizado nos algoritmos estudados anteriormente, a medida que λ cresce menos flexível torna-se o filtro. Desse modo, é mais fácil para esses novos cenários adaptarem-se à evolução do canal com maior facilidade. Além disso, novamente foi possível observar o impacto da ordem do RLS na estabilidade da evolução do MSE, onde para o cenário $M = 3$ foi verificado um melhor desempenho do que para o cenário $M = 2$.

Por fim, nos resta analisar o impacto da SNR na estabilidade e desempenho do RLS. Nas Figuras 4.7 e 4.8 temos o equivalente ao primeiro par de cenários, mas agora com a diferença de que ambos os cenários são de SNR infinita. Para o primeiro caso com $M = 2$ vemos uma estabilização perfeita dos coeficientes do filtro e uma evolução do erro MSE que tende ao erro de precisão da máquina. Dessa forma, podemos considerar esse um cenário ideal para o RLS. Sequencialmente, na figura seguinte consideramos um cenário $M = 3$ e podemos verificar que não existiu convergência para esse cenário. Inicialmente existiu uma certa estabilização na evolução do MSE, mas após algumas iterações o filtro perdeu a estabilidade e seus coeficientes "explodiram". Esse comportamento pode ser explicado tanto pelo aumento da ordem do filtro quanto pelo fator de esquecimento que torna o filtro muito pouco flexível e suscetível a instabilidades provocadas por mudanças repentinas. Por fim, nas Figuras 4.9 e 4.10 temos dois resultados estáveis na evolução do MSE e nos coeficientes do filtro RLS. Isso se deve principalmente a um fator de esquecimento que fornece maior capacidade de resistir a instabilidades geradas pelo canal.




Figura 4.3: SNR = 3 dB, $M = 2$ and $\lambda = 0.9$




Figura 4.4: SNR = 3 dB, $M = 3$ and $\lambda = 0.9$




Figura 4.5: SNR = 3 dB, $M = 2$ and $\lambda = 0.99$




Figura 4.6: SNR = 3 dB, $M = 3$ and $\lambda = 0.99$




Figura 4.7: $\text{SNR} = \infty$ dB, $M = 2$ and $\lambda = 0.9$




Figura 4.8: $\text{SNR} = \infty$ dB, $M = 3$ and $\lambda = 0.9$




Figura 4.9: $\text{SNR} = \infty$ dB, $M = 2$ and $\lambda = 0.99$




Figura 4.10: $\text{SNR} = \infty$ dB, $M = 3$ and $\lambda = 0.99$

4.4 Equalização de Canais

Organizar

1. Calcule a adaptação do algoritmo usando o RLS e mostre a evolução temporal dos coeficientes.

Solução:

A evolução temporal dos coeficientes do filtro pode ser encontrada na Figura 4.11. Aqui é possível verificar a convergência e estabilização dos coeficientes do filtro partindo do zero a medida que o número de iterações cresce. Existem algumas oscilações ao final do processo, mas nada considerável. Caso o fator de esquecimento fosse aumentado possivelmente haveriam oscilações com maiores magnitudes nos coeficientes de filtro.

2. Obtenha as trajetórias sobre as curvas de nível, tendo condições iniciais nulas para os coeficientes do equalizador. Verifique qual a melhor inicialização do algoritmo RLS. Compare com os algoritmos LMS, LMS-Normalizado e Gauss-Newton.

Solução:

As trajetórias dos algoritmos Newton, Gradiente, LMS e NLMS estão disponíveis nas Figuras ??, ??, ?? e ??. Na Figura 4.12 é apresentado o traçado da trajetória de convergência para o RLS. É possível verificar que o RLS apresenta um comportamento de convergência na superfície MSE mais próximo do algoritmo LMS. Existem alguns outliers durante o processo de filtragem, mas de modo geral o filtro tende à solução ótima de uma forma mais organizada e estável do que o NLMS.

3. Obtenha também a evolução do erro quadrático médio para cada um dos algoritmos anteriores.

Solução:

As evolução do erro quadrático médio para os algoritmos Newton, Gradiente, LMS e NLMS já foram abordadas na seção anterior e podem ser revisitadas nas Figuras ??, ??, ?? e ??. adicionalmente, o traçado da evolução do MSE para o método RLS está presente na Figura 4.13. Nessa figura podemos verificar que o RLS apresenta uma latência de convergência menor que o LMS e NLMS, mas ao final do processo aparentemente o grau de estabilidade da solução dos coeficientes de filtro parece ser menor do que quando comparamos com os quatro algoritmos de filtragem mencionados anteriormente.

4.5 Equalização Adaptativa

Organizar

Assim como na questão da lista anterior foi considerado novamente que o filtro é de ordem $M = 15$. Os resultados podem ser encontrados nas Figuras 4.14, 4.15, 4.16 e 4.17. Inicialmente é possível confirmar uma evidente vantagem na velocidade de convergência do RLS quando o comparamos com o algoritmo LMS. Independentemente do fator de esquecimento considerado todos apresentam uma vantagem considerável sobre o LMS quando se observa tanto a latência quanto o desempenho da evolução do MSE. Desse modo, o RLS tem menor latência e melhor desempenho MSE quando comparamos com o LMS.

Já quando voltamos nossa análise para o impacto do fator de esquecimento é possível verificar uma interessante característica do RLS. O fator de esquecimento atua de forma semelhante ao passo de aprendizado nos algoritmos LMS e NLMS, mas num sentido um pouco diferente.




Figura 4.11: Convergência dos coeficientes para o RLS. Amostras = 5000, $M = 2$, $\lambda = 0.99$




Figura 4.12: Caminho de convergência na superfície MSE para o RLS. Amostras = 5000, $M = 2$, $\lambda = 0.99$




Figura 4.13: Comportamento da evolução do MSE para o RLS. Amostras = 5000, $M = 2$, $\lambda = 0.99$

Desse modo, quanto maior o seu valor mais flexível torna-se o filtro para adaptar-se a novos estímulos. Assim, nas Figuras 4.15 e 4.16, onde o fator de esquecimento é definido respectivamente por $\lambda = 0.9$ e $\lambda = 0.99$, é possível ver que o MSE apresenta oscilações de elevadas magnitudes mesmo após a convergência pois estamos restringindo a flexibilidade do RLS. Já na Figura 4.17 onde temos um fator de esquecimento definido por $\lambda = 0.999$ temos oscilações de magnitudes consideravelmente menores quando comparamos com os dois casos anteriores. Já com relação ao valor de convergência MSE não é possível notar grandes diferenças entre os casos considerados, visto que todos oscilam em torno de um valor aproximadamente igual.

Por fim, nas Figuras 4.18 e 4.19 são traçados os gráficos da evolução temporal e da resposta em frequência para o cenário proposto, respectivamente. Na primeira figura vemos a adaptação do algoritmo RLS a medida que o número de iterações progride e, apesar do equalizador desconhecer o sinal verdadeiro, existe uma aparente melhora de desempenho a medida que o filtro progride. Já na figura seguinte são comparados diretamente as repostas em frequência dos filtros LMS e RLS em relação ao sistema desconhecido com $\mu = 0.001$ e $\lambda = 0.999$, respectivamente. A partir de tal resultado podemos verificar que o filtro RLS consegue adaptar-se mais facilmente ao sistema desconhecido enquanto o filtro LMS apresenta intensas variações que possivelmente prejudicariam o processo de filtragem.




Figura 4.14: Comportamento da evolução do MSE para o LMS. Amostras = 500, $M = 15$, $\mu = 0.001$




Figura 4.15: Comportamento da evolução do MSE para o RLS. Amostras = 500, $M = 15$, $\lambda = 0.9$




Figura 4.16: Comportamento da evolução do MSE para o RLS. Amostras = 500, $M = 15$, $\lambda = 0.99$




Figura 4.17: Comportamento da evolução do MSE para o RLS. Amostras = 500, $M = 15$, $\lambda = 0.999$




Figura 4.18: Evolução temporal para o RLS. Amostras = 500, $M = 15$, $\lambda = 0.999$




Figura 4.19: Comparativo da resposta em frequência para LMS e RLS. Amostras = 500, $M = 15$, $\lambda = 0.999$



Filtragem Adaptativa - TIP 7188

Prof. Dr. Charles Casimiro Cavalcante
Período: 2018.2

Lista de Exercícios No. 4: Método dos Mínimos Quadrados

1. O algoritmo RLS é utilizado para prever o sinal $x(n) = \cos\left(\frac{\pi n}{3}\right)$ usando um filtro FIR de segunda ordem com o primeiro coeficiente fixo em 1. Dado $\lambda = 0.98$, calcule o sinal de saída $y(n)$ e os coeficientes do filtro nas primeiras 10 iterações. Note que a meta é minimizar $E\{y^2(n)\}$. Inicie com $\mathbf{w} = [1 \ 0 \ 0]^T$ e $\delta = 100$.

2. Seja $\epsilon(n)$ que denota um erro de estimação *a priori*

$$\epsilon(n) = d(n) - \mathbf{w}^H(n-1)\mathbf{x}(n)$$

em que $d(n)$ é a resposta desejada, $\mathbf{x}(n)$ é o vetor de entrada do filtro e $\mathbf{w}(n-1)$ é a estimativa anterior do vetor de coeficientes do filtro. Seja $e(n)$ o erro de estimação *a posteriori*

$$e(n) = d(n) - \mathbf{w}^H(n)\mathbf{x}(n)$$

em que $\mathbf{w}(n)$ é a estimativa atual do vetor de coeficientes do filtro. Para dados complexos ambos $\epsilon(n)$ e $e(n)$ são de valores complexos. Mostre que o produto $\epsilon(n)e^*(n)$ é sempre de valor real.

3. Seja um sinal $x(n)$ composto de uma senóide em meio à ruído. Simule um preditor adaptativo de ordem 2 com um algoritmo RLS considerando $\text{SNR} = 3$ dB e $\text{SNR} \rightarrow \infty$. Variando o fator de esquecimento e/ou as condições iniciais verifique e comente sobre a ocorrência ou não de instabilidade numérica. Repita o procedimento como preditor de ordem 3.
4. Considere um sinal branco gaussiano de variância unitária transmitido por um canal de comunicação de função de transferência $H(z) = 1 + 1.6z^{-1}$. Para compensar este canal utiliza-se um equalizador dado por $W(z) = w_0 + w_1z^{-1}$. (Problema da lista de exercícios no. 3).
- (a) Calcule a adaptação do algoritmo usando o RLS.
 - (b) Obtenha as trajetórias sobre as curvas de nível, tendo condições iniciais nulas para os coeficientes do equalizador. Verifique qual a melhor inicialização do algoritmo RLS. Compare com os algoritmos LMS, LMS-Normalizado e Gauss-Newton.
 - (c) Obtenha também a evolução do erro quadrático médio para cada um dos algoritmos anteriores.
5. Seja a questão 6 da lista de exercícios anterior (Algoritmos Recursivos - questão sobre Equalização Adaptativa). Implemente o RLS para a equalização do sistema considerado na letra (a) da mesma. Compare os resultados obtidos com o LMS. Verifique a velocidade de convergência para os casos de $\lambda = 0.9$, $\lambda = 0.99$ e $\lambda = 0.999$.

5 Implementações em MATLAB

A implementação é dividida em dois arquivos. O primeiro é chamado *filter_hw.m*³, onde há a definição dos métodos utilizados nos problemas. O segundo é o script *main.m*⁴, que chama os métodos para serem executados. São apresentados nas sessões 5.1 e 5.2, respectivamente.

³*filter_hw.m*: https://github.com/lucasabdalalah/Courses-HWs/blob/master/Master/TIP7188-FILTRAGEM_ADAPTATIVA/homework/code/filter_hw.m

⁴*main.m*: https://github.com/lucasabdalalah/Courses-HWs/blob/master/Master/TIP7188-FILTRAGEM_ADAPTATIVA/homework/code/main.m.

Table of Contents

MÉTODOS	1
HOMEWORK 2 - PROBLEM 5	1
HOMEWORK 3 - PROBLEM 4	2
HOMEWORK 3 - PROBLEM 5	7
HOMEWORK 3 - PROBLEM 6	11
HOMEWORK 4 - PROBLEM 1	24
HOMEWORK 4 - PROBLEM 3	25
VERBOSE DETAILS	35
SAVE DATA TO TXT FILE	35

MÉTODOS

[TIP7188 - Filtragem Adaptativa] Author: Lucas Abdalah

filter_hw.m

filter_hw is a package developed for the Adaptive Filtering Course It is a way to make a compilation for all function

CONTENT

HOMEWORK 2 - PROBLEM 5

SAVE DATA TO TXT FILE

```
filter_hw.MAT2TXT    - Write a matrix X into a txt file
filter_hw.TENSOR2TXT - Write a 3D tensor X into a txt file
```

PLACE HOLDER

```
classdef filter_hw
```

```
methods(Static)
```

HOMEWORK 2 - PROBLEM 5

```
function hw2p5(varargin)
% FILTER_HW.HW2P5 Perform the error surface propose on the Hw 2,
% problem 5
%
% See also.

if isempty(varargin)
    save_results = false;
else
    save_results = varargin{1};
end

N = 25;
```

```

w_lim = 100;
w = [linspace(-w_lim,w_lim,N); linspace(-w_lim,w_lim,N)];
[w_0, w_1] = meshgrid(w(1,:), w(2,:));
J_surface = @(w_0, w_1) 24.40 - 4.*w_0 - 9.*w_1 + w_0.^2 + w_1.^2;
J = J_surface(w_0, w_1);
h = figure();
surf(w_0, w_1, J, 'EdgeColor', 'none');
colormap turbo;
xlabel('$w_0$', 'FontSize', 16, 'interpreter', 'latex');
ylabel('$w_1$', 'FontSize', 16, 'interpreter', 'latex');
zlabel('$J$', 'FontSize', 16, 'interpreter', 'latex');
view([-24.5036297640653 47.6514617014408]);
colorbar('box', 'off');
grid on;
axis tight;
pathName = 'figures/';
filter_hw.export_fig(save_results, h, [pathName, 'hw2p5']);
end

```

HOMWORK 3 - PROBLEM 4

```

function filter_path(signal_d_var, weights, wiener, Rx, p, c_)
% FILTER_HW.FILTER_PATH Perform the weights path surface
%
% See also.
step = 0.25;
X = meshgrid (-1:step:1,-1:step:1);
w = [X(:), reshape(transpose(X),[],1)];
[wLen, ~] = size(w);
J = zeros(wLen, 1);
for n = 1:wLen
    J(n) = signal_d_var - 2*w(n,:)*p + w(n,:)*Rx*w(n,:).';
end
contour(X, X', reshape(J,size(X)), '-.', 'color', 'k');
hold on;
scatter(weights(1,:), weights(2, :), '.', 'MarkerEdgeColor', c_);
hold off;
ha = annotation('textarrow', [0 0], [0 0], 'String', 'Wiener');
ha.Parent = gca;
ha.X = [wiener(1)+0.15 wiener(1)];
ha.Y = [wiener(2)-0.4 wiener(2)];
grid on;

end

function [error, weights] = dga(signal_x, signal_d, order, mi, Rx, p)
% FILTER_HW.DGA Perform the Deterministic Gradient Algorithm
%
% See also.
N = length(signal_x);
error = zeros(N,1);
weights = zeros(order, N);
signal_d = signal_d(order:end,1);

```

```

        for n = 1:(N - order - 1)
            error(n,1) = signal_d(n) - weights(:,n)'\*signal_x(n:n
+order-1);
            weights(:,n+1) = weights(:,n) - 2*mi*(Rx*weights(:,n) - p);
        end
    end
end

```

```

function [error, weights] = lms(signal_x, signal_d, order, mi)
% FILTER_HW.LMS Perform the LMS Algorithm
%
% See also.
N = length(signal_x);
error = zeros(N,1);
weights = zeros(order, N);
signal_d = signal_d(order:end,1);

    for n = 1:(N - order - 1)
        error(n) = signal_d(n) - weights(:,n)' * signal_x(n:n
+order-1);
        weights(:,n+1) = weights(:,n) + 2 * mi * error(n) *
signal_x(n:n+order-1);
    end
    weights = flip(weights);
end

```

```

function [error, weights] = newton(signal_x, signal_d, order, mi,
wiener)
% FILTER_HW.NEWTON Perform the Newton Algorithm
%
% See also.
N = length(signal_x);
error = zeros(N,1);
weights = zeros(order, N);
signal_d = signal_d(order:end,1);

    for n = 1:(N - order - 1)
        error(n,1) = signal_d(n) - weights(:,n)'\*signal_x(n:n
+order-1);
        weights(:,n+1) = weights(:,n) - mi*(weights(:,n) - wiener);
    end
end

```

```

function [error, weights] = nlms(signal_x, signal_d, order, mi, gamma)
% FILTER_HW.NLMS Perform the NLMS Algorithm
%
% See also.
N = length(signal_x);
error = zeros(N,1);
weights = zeros(order, N);
signal_d = signal_d(order:end,1);

```

```

        for n = 1:(N - order - 1)
            mi_normalized = mi/(gamma + norm(signal_x));
            error(n) = signal_d(n) - weights(:,n)' * signal_x(n:n +
order-1);
            weights(:,n+1) = weights(:,n) + 2 * mi_normalized * error(n)
* signal_x(n:n+order-1);
        end
        weights = flip(weights);
    end

function hw3p4(varargin)

    % Save or not the results
    if isempty(varargin)
        save_results = false;
    else
        save_results = varargin{1};
    end

    pathName = 'figures/';

    h0 = figure();
    viscircles([0, 0], 1, 'Color', 'k', 'LineStyle', '-', 'LineWidth',
1.5);
    line([0 0], [-1 1], 'Color', 'k', 'HandleVisibility', 'off');
    line([-1 1], [0 0], 'Color', 'k', 'HandleVisibility', 'off');
    hold on
    scatter(-1.6, 0, 'o', 'filled');
    scatter(0.45, 0, 'o', 'filled');
    hold off
    xlabel('$\Re (Z)$', 'interpreter', 'latex');
    ylabel('$\Im (Z)$', 'interpreter', 'latex');
    axis([-1.7 1.7 -1.7 1.7]);
    legend('Channel Zeros', 'Filter Zeros', 'Location', 'Northeast');
    grid minor
    axis square

    filter_hw.export_fig(save_results, h0, [pathName, 'hw3p4-zeros']);

    % Color scheme to plot -----
    c_ = struct('dg', [57 106 177]./255, 'lms', [204 37
41]./255, 'newton', [62 150 81]./255, 'nlms', [107 76
154]./255, 'mean', 'k');
    % General Setup -----
    N = 1000; % Number of samples
    order = 2; % Filter order
    % Signal Model -----
    signal_d = randn(N,1);
    signal_d_var = var(signal_d);
    % Noisy Version -----
    Hz = [1 1.6];

```

```

    signal_x = filter(Hz,1,signal_d);
    noise = sqrt(1/(10^(inf/10))).*randn(N,1);
    signal_x = signal_x + noise;
    % Wiener Filter -----
    Rxcorr = sort(xcorr(Hz));
    Rx = reshape([Rxcorr(end) Rxcorr], [2, 2]); % Autocorrelation
matrix
    p = eye(2,1); % Cross-correlation
    wiener = Rx\p; % Wiener solution
    fprintf('Wiener solution: %2.2f \n %2.2f \n', wiener);
    % Deterministic Gradient Algorithm
    -----
    dg.mi = 1e-2;
    [dg.error, dg.weights] = filter_hw.dga(signal_x, signal_d, order,
    dg.mi, Rx, p);
    % Newton Implementation -----
    newton.mi = 5e-2;
    [newton.error, newton.weights] = filter_hw.newton(signal_x,
    signal_d, order, newton.mi, wiener);
    % LMS Algorithm -----
    lms.mi = 1e-3;
    [lms.error, lms.weights] = filter_hw.lms(signal_x, signal_d,
    order, lms.mi);
    % NLMS Algorithm -----
    nlms.mi = 5e-1;
    gamma = 0.5;
    [nlms.error, nlms.weights] = filter_hw.nlms(signal_x, signal_d,
    order, nlms.mi, gamma);
    % Plot - Deterministic Gradient Algorithm
    -----
    h1 = figure(1);
    subplot(2,1,1);
    semilogy(1:N, dg.error.^2, '-', 'color', c_.dg , "linewidth", 1); %
MSE
    hold on
    semilogy(1:N, repelem(mean(dg.error.^2), N), '--', 'color',
    c_.mean, "linewidth", 1);
    hold off
    xlabel('Iterations');
    ylabel('MSE');
    legend('Deterministic Gradient', 'Mean', 'Location', 'Best')
    grid on;
    axis tight
    subplot(2,1,2);
    filter_hw.filter_path(signal_d_var, dg.weights, wiener, Rx, p,
    c_.dg); % Solution Path
    xlabel('$w_1$', 'interpreter', 'latex');
    ylabel('$w_0$', 'interpreter', 'latex');
    legend('Solution Contour', 'Deterministic
Gradient', 'Location', 'Northeast')
    axis tight

    filter_hw.export_fig(save_results, h1, [pathName, 'hw3p4-dga']);

```

```

% Plot - Newton Implementation
-----
h2 = figure(2);
subplot(2,1,1);
semilogy(1:N, newton.error.^2, '-', 'color', c_.newton, "linewidth",
1); % MSE Curve
hold on
semilogy(1:N, repelem(mean(newton.error.^2), N), '--', 'color',
c_.mean, "linewidth", 1);
hold off
xlabel('Iterations');
ylabel('MSE');
legend('Newton', 'Mean', 'Location', 'Best');
grid on;
axis tight
subplot(2,1,2);
filter_hw.filter_path(signal_d_var, newton.weights, wiener, Rx, p,
c_.newton);
xlabel('$w_1$', 'interpreter', 'latex');
ylabel('$w_0$', 'interpreter', 'latex');
legend('Solution Contour', 'Newton', 'Location', 'Northeast')
axis tight

filter_hw.export_fig(save_results, h2, [pathName, 'hw3p4-
newton']);

% Plot - LMS Algorithm -----
h3 = figure(3);
subplot(2,1,1);
semilogy(1:N, lms.error.^2, '-', 'color', c_.lms, "linewidth",
1); % MSE
hold on
semilogy(1:N, repelem(mean(lms.error.^2), N), '--', 'color',
c_.mean, "linewidth", 1);
hold off
xlabel('Samples, N');
ylabel('MSE');
legend('LMS', 'Mean', 'Location', 'Best')
grid on;
axis tight
subplot(2,1,2);
filter_hw.filter_path(signal_d_var, lms.weights, wiener, Rx, p,
c_.lms); % Solution Path
xlabel('$w_1$', 'interpreter', 'latex');
ylabel('$w_0$', 'interpreter', 'latex');
legend('Solution Contour', 'LMS', 'Location', 'Northeast')
axis tight

filter_hw.export_fig(save_results, h3, [pathName, 'hw3p4-lms']);

% Plot - NLMS Implementation -----
h4 = figure(4);
subplot(2,1,1);
semilogy(1:N, nlms.error.^2, '-', 'color', c_.nlms, "linewidth", 1);

```

```

        hold on
        semilogy(1:N, repelem(mean(nlms.error.^2), N), '--', 'color',
c_.mean, "linewidth", 1);
        hold off
        xlabel('Samples, N');
        ylabel('MSE');
        legend('NLMS', 'Mean', 'Location', 'Best');
        grid on;
        axis tight
        subplot(2,1,2);
        filter_hw.filter_path(signal_d_var, nlms.weights, wiener, Rx, p,
c_.nlms);
        xlabel('$w_1$', 'interpreter', 'latex');
        ylabel('$w_0$', 'interpreter', 'latex');
        legend('Solution Contour', 'NLMS', 'Location', 'Northeast')
        axis tight

        filter_hw.export_fig(save_results, h4, [pathName, 'hw3p4-nlms']);

end

```

HOMWORK 3 - PROBLEM 5

```

function [error, weights, signal_d_hat] = hw3p5_lms(signal_x,
signal_d, M, mi)
    N = length(signal_x);
    error = zeros(N,1);
    weights = zeros(M, N);
    signal_d_hat = zeros(size(signal_x));

    for ss = 1:(N - M)
        signal_d_hat(ss) = weights(:,ss)'*signal_x(ss:ss+M-1);
        error(ss) = signal_d(ss) - weights(:,ss)' * signal_x(ss:ss
+M-1);
        weights(:,ss+1) = weights(:,ss) + 2 * mi * error(ss) *
signal_x(ss:ss+M-1);
    end
    signal_d_hat = zscore(signal_d_hat);
end

function hw3p5(varargin)
    % General Setup
    c_ = struct('original', [57 106 177]./255, 'estimated', [204 37
41]./255, 'lms', [107 76 154]./255, 'mean', 'k');
    order = 15; M = order + 1;
    N = 5000 + M; % Number of samples
    mi_ceil = 1/97;

    % Signal Model
    SNR_dB = 30;
    SNR_li = 10^(SNR_dB/10);
    variance_noise = 1/SNR_li;

```

```

noise = sqrt(variance_noise).*randn(N,1);
signal_d = zscore(randn(N,1)); % Z-score Normalization
Hz = ones(1,12);
signal_x = filtfilt(Hz,1,signal_d);
signal_x = zscore(signal_x + noise);

[mu02.error, mu02.weights, mu02.signal_d_hat] =
filter_hw.hw3p5_lms(signal_x, signal_d, M, mi_ceil/2);
[mu10.error, mu10.weights, mu10.signal_d_hat] =
filter_hw.hw3p5_lms(signal_x, signal_d, M, mi_ceil/10);
[mu50.error, mu50.weights, mu50.signal_d_hat] =
filter_hw.hw3p5_lms(signal_x, signal_d, M, mi_ceil/50);

% Plot - mu/2
h1 = figure();
subplot(3,1,1)
semilogy(1:N, abs(mu02.error).^2, '-', 'color',
c_.lms , "linewidth", 1);
hold on
semilogy(1:N, repelem(mean(abs(mu02.error).^2), N), '--', 'color',
c_.mean , "linewidth", 1);
hold off
xlabel('Samples, N');
xlim([0 N]);
ylabel('MSE');
legend('LMS', 'Mean', 'Location', 'Best');
title('$\mu_{\max}/2$', 'interpreter', 'latex')
grid on;

subplot(3,1,2)
[Hf,wf] = freqz(mu02.weights(:, N - M + 1).',1, 'whole', 512);
[Hc,wc] = freqz(ones(1,12), 1, 'whole', 512);
plot(wc/pi,20*log10(abs(Hc)), '--', 'color',
c_.original, "linewidth", 1.5);
hold on;
plot(wf/pi,20*log10(abs(Hf)), '-', 'color',
c_.estimated, "linewidth", 1.5);
xlabel('Normalized Frequency (\times\pi rad/sample)')
ylabel('Magnitude (dB)')
legend('System', 'Filter', 'Location', 'Best');
grid on;

subplot(3,1,3)
plot(1:N, signal_d, '--', 'color', c_.original, "linewidth", 1.5);
hold on;
plot(1:N, mu02.signal_d_hat, '-', 'color',
c_.estimated, "linewidth", 1.5);
xlabel('Samples, N');
xlim([1000 1050]);
ylabel('Magnitude');
legend('Original', 'Estimated', 'Location', 'Best');
grid on;
% savefig_tight(h1, 'figures/hw3p5b-mu02', 'both');

```

```

% Plot - mu/10
h2 = figure();
subplot(3,1,1)
semilogy(1:N, abs(mu10.error).^2, '-', 'color',
c_.lms , "linewidth", 1);
hold on
semilogy(1:N, repelem(mean(abs(mu10.error).^2), N), '--', 'color',
c_.mean , "linewidth", 1);
hold off
xlabel('Samples, N');
xlim([0 N]);
ylabel('MSE');
legend('LMS', 'Mean', 'Location', 'Best');
title('$\mu_{\max}/10$', 'interpreter', 'latex')
grid on;

subplot(3,1,2)
[Hf,wf] = freqz(mu10.weights(:, N - M + 1), 1, 'whole', 512);
[Hc,wc] = freqz(ones(1,12), 1, 'whole', 512);
plot(wc/pi, 20*log10(abs(Hc)), '--', 'color',
c_.original, "linewidth", 1.5);
hold on;
plot(wf/pi, 20*log10(abs(Hf)), '-', 'color',
c_.estimated, "linewidth", 1.5);
xlabel('Normalized Frequency (\times\pi rad/sample)')
ylabel('Magnitude (dB)')
legend('System', 'Filter', 'Location', 'Best');
grid on;

subplot(3,1,3)
plot(1:N, signal_d, '--', 'color', c_.original, "linewidth", 1.5);
hold on;
plot(1:N, mu10.signal_d_hat, '-', 'color',
c_.estimated, "linewidth", 1.5);
xlabel('Samples, N');
xlim([4000 4050]);
ylabel('Magnitude');
legend('Original', 'Estimated', 'Location', 'Best');
grid on;
% savefig_tight(h2, 'figures/hw3p5b-mu10', 'both');

% Plot - mu/50
h3 = figure();
subplot(3,1,1)
semilogy(1:N, abs(mu50.error).^2, '-', 'color',
c_.lms , "linewidth", 1);
hold on
semilogy(1:N, repelem(mean(abs(mu50.error).^2), N), '--', 'color',
c_.mean , "linewidth", 1);
hold off
xlabel('Samples, N');
xlim([0 N]);
ylabel('MSE');
legend('LMS', 'Mean', 'Location', 'Best');

```

```

title('$\mu_{\max}/50$', 'interpreter', 'latex')
grid on;

subplot(3,1,2)
[Hf,wf] = freqz(mu50.weights(:, N - M + 1).',1, 'whole', 512);
[Hc,wc] = freqz(ones(1,12), 1, 'whole', 512);
plot(wc/pi,20*log10(abs(Hc)), '--', 'color',
c_.original, "linewidth", 1.5);
hold on;
plot(wf/pi,20*log10(abs(Hf)), '-', 'color',
c_.estimated, "linewidth", 1.5);
xlabel('Normalized Frequency (\times\pi rad/sample)')
ylabel('Magnitude (dB)')
legend('System', 'Filter', 'Location', 'Best');
grid on;

subplot(3,1,3)
plot(1:N, signal_d, '--','color', c_.original, "linewidth", 1.5);
hold on;
plot(1:N, mu50.signal_d_hat, '-', 'color',
c_.estimated, "linewidth", 1.5);
xlabel('Samples, N');
xlim([4000 4050]);
ylabel('Magnitude');
legend('Original', 'Estimated', 'Location', 'Best');
grid on;
% savefig_tight(h3, 'figures/hw3p5b-mu50', 'both');

% Misadjustment for all scenarios
Mcoef = 12;
Rxx = zeros(Mcoef,Mcoef);
RMC = 10000;

for k = 1:RMC
    x = zscore(randn(RMC,1) + randn(RMC,1));
    y = zeros(length(x) + Mcoef - 1, 1);
    for i = Mcoef:length(x)
        for ii = 0:11
            y(i + Mcoef - 1) = y(i + Mcoef - 1) + x(i - ii);
        end
    end
    [~,R] = corrmtx(y, Mcoef - 1, 'autocorrelation');

    Rxx = Rxx + R;
end

Rxx = Rxx./RMC;

rTrace = trace(Rxx);
rTraceceil = trace(ceil(Rxx));

mis.the02 = ((0.05/2)*(rTraceceil))/(1 - (0.05/2)*(rTraceceil));
mis.emp02 = ((0.05/2)*(rTrace))/(1 - (0.05/2)*(rTrace));

```

```

mis.the10 = ((0.05/10)*(rTraceceil))/(1 - (0.05/10)*(rTraceceil));
mis.emp10 = ((0.05/10)*(rTrace))/(1 - (0.05/10)*(rTrace));
mis.the50 = ((0.05/50)*(rTraceceil))/(1 - (0.05/50)*(rTraceceil));
mis.emp50 = ((0.05/50)*(rTrace))/(1 - (0.05/50)*(rTrace));

Export = [mis.the02 mis.emp02; mis.the10 mis.emp10; mis.the50
mis.emp50];
filter_hw.mat2txt('hw3p5mis.txt', Export, 'w', 'Misadjustment');

fprintf('Misadjustment ----- \n\t Emp | The \n');
fprintf('\t %2.4f | %2.4f \n', Export');
end

```

HOMWORK 3 - PROBLEM 6

```

function SER = hw3p6(varargin)
    % (a) -----
    c_ = struct('original', [57 106 177]./255, 'estimated', [204 37
41]./255, 'nlms', [107 76 154]./255, 'mean', 'k');

    disp('a')
    % Training Phase
    -----

    % General setup
    mi = 0.4e-0;
    gamma = 1e-3;
    order = 15; M = order + 1;
    N = 500; % Samples

    % Empty vectors to fill with obtained coefficients.
    error = zeros(N,1);
    weights = zeros(M, N);

    % Signal Model
    SNR = inf;
    QAM_train = 4;
    signal_d_train = randi([0,QAM_train - 1],[N 1]);
    signal_d_train = qammod(signal_d_train,QAM_train);
    Hz = [0.5 1.2 1.5 -1];
    signal_x_train = filtfilt(Hz,1,signal_d_train);
    snr = 10^(SNR/10);
    energy = mean(abs(signal_x_train(:)).^2);
    noise = sqrt(energy.*1/snr/2) * (complex(randn(N,1), randn(N,1)));

    % Generating the noisy received signal.
    signal_x_train = signal_x_train + noise;
    % NLMS algorithm
    for s = M:N
        window_x = signal_x_train(s:-1:s-M+1);
        mi_normalized = mi/(gamma + norm(window_x)^2);
        error(s) = signal_d_train(s-M+1) - weights(:,s)'*window_x;
        weights(:,s+1) = weights(:,s) + mi_normalized * conj(error(s))
    * window_x;

```

```

end

% Transmission
-----

N = 5000 + M;

% Signal Model
SNR = 30;
QAM = 16;
signal_d = randi([0,QAM - 1],[N 1]); % The same pilot for every
pilot frame and block.
signal_d = qammod(signal_d,QAM); % 4-QAM Pilot Signal.
signal_x = filtfilt(Hz,1,signal_d);
snr = 10^(SNR/10);
energy = mean(abs(signal_x(:)).^2); % Energy symbol pilot.
noise = sqrt(energy.*1/snr/2) * (complex(randn(N,1), randn(N,1)));
signal_x = signal_x + noise;

% Empty vectors to fill with obtained coefficients.
weightsShape = weights(:,s+1);
error = zeros(N,1);
weights = zeros(M, N);
weights(:,M) = weightsShape;
signal_d_hat = zeros(size(signal_d));

% NLMS algorithm with QAM signal
for s = M:N
    window_x = signal_x(s:-1:s-M+1);
    mi_normalized = mi/(gamma + norm(window_x)^2);
    signal_d_hat(s-M+1) = weights(:,s)'*window_x; % Filtering the
signal
    error(s) = qammod(qamdemod(signal_x(s-M+1),QAM),QAM) -
weights(:,s)'*window_x;
    weights(:,s+1) = weights(:,s) + mi_normalized * conj(error(s))
* window_x;
end

% MSE Curve
h1 = figure();
semilogy(1:N, abs(error).^2, '-', 'color', c_.nlms , "linewidth",
1);
hold on
semilogy(1:N, repelem(mean(abs(error).^2), N), '--', 'color',
c_.mean , "linewidth", 1);
hold off
xlabel('Samples, N');
ylabel('MSE');
xlim([0 N]);
legend('NLMS', 'Mean', 'Location', 'Best');
grid on;
% savefig_tight(h1, 'figures/hw3p6a-MSE', 'both');

% Temporal Evolution
ShowEvolution = qamdemod(signal_d_hat,QAM);

```

```

    Lsamples = 50;
    h2 = figure();
    subplot(2,2,1)
    stem(1:Lsamples, qamdemod(signal_d(1:Lsamples),QAM),'-', 'color',
c_.original, "linewidth", 1, "markersize", 2);
    hold on;
    stem(1:Lsamples, ShowEvolution(1:Lsamples), '--', 'color',
c_.estimated, "linewidth", 1, "markersize", 2);
    hold off;
    xlabel('Sample, N');
    ylabel('Magnitude');
    axis([0 50 0 20])
    grid on;
    subplot(2,2,2)
    stem(300:350, qamdemod(signal_d(300:350),QAM),'-', 'color',
c_.original, "linewidth", 1, "markersize", 2);
    hold on;
    stem(300:350, ShowEvolution(300:350), '--', 'color',
c_.estimated, "linewidth", 1, "markersize", 2);
    hold off;
    xlabel('Sample, N');
    ylabel('Magnitude');
    axis([300 350 0 20])

legend('Original', 'Estimated', 'Location', 'northeastoutside', 'Orientation', 'Horizontal', 'Units', 'normalized');
legend boxoff
grid on;
subplot(2,2,3)
stem(3000:3050, qamdemod(signal_d(3000:3050),QAM),'-', 'color',
c_.original, "linewidth", 1, "markersize", 2);
hold on;
stem(3000:3050, ShowEvolution(3000:3050), '--', 'color',
c_.estimated, "linewidth", 1, "markersize", 2);
hold off;
xlabel('Sample, N');
ylabel('Magnitude');
axis([3000 3050 0 20])
grid on;
subplot(2,2,4)
stem((5000-Lsamples):5000, qamdemod(signal_d((5000-
Lsamples):5000),QAM),'-', 'color', c_.original, "linewidth",
1, "markersize", 2);
hold on;
stem((5000-Lsamples):5000, ShowEvolution((5000-
Lsamples):5000), '--', 'color', c_.estimated, "linewidth",
1, "markersize", 2);
hold off;
xlabel('Sample, N');
ylabel('Magnitude');
axis([4950 5000 0 20])
grid on;
% savefig_tight(h2, 'figures/hw3p6a-evolution', 'both');

```

```

% Plot Results
h3 = figure();
subplot(2,2,1)
plot(signal_d_train, '.', 'color', 'y', "markersize", 8)
title('Training');
xlabel('In Phase');
ylabel('Quadrature');
axis([-2 2 -2 2]);
set(gca, 'Color', 'k');
subplot(2,2,2)
plot(signal_d, '.', 'color', 'y', "markersize", 8)
title('Original');
xlabel('In Phase');
ylabel('Quadrature');
set(gca, 'Color', 'k');
subplot(2,2,3)
plot(signal_x, '.', 'color', 'y', "markersize", 8)
title('Transmitted');
xlabel('In Phase');
ylabel('Quadrature');
set(gca, 'Color', 'k');
subplot(2,2,4)

plot(qammod(qamdemod(signal_d_hat, QAM), QAM), '.', 'color', 'y', "markersize",
8)
title('Filter and Decisor');
xlabel('In Phase');
ylabel('Quadrature');
set(gca, 'Color', 'k');
set(gcf, 'InvertHardcopy', 'off')

% savefig_tight(h3, 'figures/hw3p6a-QAM', 'both');

% General setup

% (b) -----
disp('b')

% General setup
mi = 1e-3;
order = 15; M = order + 1;
N = 5000 + 50;

% Signal Model
SNR = 30;
QAM = 16;
signal_d = qammod(randi([0, QAM - 1], [N 1]), QAM);
Hz = [0.5 1.2 1.5 -1];
signal_x = filter(Hz, 1, signal_d);
snr = 10^(SNR/10);
energy = mean(abs(signal_x(:)).^2); % Energy symbol pilot.
noise = sqrt(energy.*(1/snr)/2)*complex(randn(N,1), randn(N,1));
signal_x = signal_x + noise;

```

```

% Training (50 Samples)
N = 50;
error = zeros(N,1);
weights = zeros(M, N);

% Signal Model
QAM_train = 4;
signal_d_train = (1/sqrt(2)) * qammod(randi([0,QAM_train - 1],[N
1]),QAM_train);
Hz = [0.5 1.2 1.5 -1];
signal_x_train = filter(Hz,1,signal_d_train);
snr = 10^(inf/10);
energy = mean(abs(signal_x_train(:)).^2);
noise = sqrt(energy.*1/snr/2) * (complex(randn(N,1), randn(N,1)));
signal_x_train = signal_x_train + noise;

% LMS algorithm
for s = M:N
    window_x = signal_x_train(s:-1:s-M+1);
    error(s) = signal_d_train(s-M+1) - weights(:,s)'*window_x;
    weights(:,s+1) = weights(:,s) + 2 * mi * conj(error(s)) *
window_x;
end

% Transmission
N = 5000 + 50; % Samples

% Empty vectors
weights = zeros(M, N);
error = zeros(N,1);
weightsShape = weights(:,s+1);
weights(:,M) = weightsShape;
signal_d_hat_50 = zeros(size(signal_d));

for s = M:N
    windowX= signal_x(s:-1:s-M+1);
    signal_d_hat_50(s-M+1) = weights(:,s)'*windowX;
    error(s) = qammod(qamdemod(signal_x(s-M+1),QAM),QAM) -
weights(:,s)'*windowX;
    weights(:,s+1) = weights(:,s) + 2 * mi * conj(error(s)) *
windowX;
end

% Training (150 Samples)
N = 150;
% Empty vectors
error = zeros(N,1);
weights = zeros(M, N);

% Signal Model
QAM_train = 4;
signal_d_train = randi([0,QAM_train - 1],[N 1]);
signal_d_train = (1/sqrt(2)) * qammod(signal_d_train,QAM_train);

```

```

Hz = [0.5 1.2 1.5 -1];
signal_x_train = filter(Hz,1,signal_d_train);
snr = 10^(inf/10);
energy = mean(abs(signal_x_train(:)).^2);
noise = sqrt(energy.*1/snr/2) * (complex(randn(N,1), randn(N,1)));
signal_x_train = signal_x_train + noise;

% LMS
for s = M:N
    aux = signal_x_train(s:-1:s-M+1);
    error(s) = signal_d_train(s-M+1) - weights(:,s)'*aux;
    weights(:,s+1) = weights(:,s) + 2 * mi * conj(error(s)) *
windowX;
end

% Transmission

N = 5000 + 50; % Samples
% Empty vectors
error = zeros(N,1);
weightsShape = weights(:,s+1);
weights = zeros(M, N);
weights(:,M) = weightsShape;
signal_d_hat_150 = zeros(size(signal_d));

% LMS algorithm
for s = M:N
    windowX= signal_x(s:-1:s-M+1);
    signal_d_hat_150(s-M+1) = weights(:,s)'*windowX;
    error(s) = qammod(qandemod(signal_x(s-M+1),QAM),QAM) -
weights(:,s)'*windowX;
    weights(:,s+1) = weights(:,s) + 2 * mi * conj(error(s)) *
windowX;
end

% Training (300 Samples)
N = 300;
% Empty vectors
error = zeros(N,1);
weights = zeros(M, N);
% Signal Model
QAM_train = 4;
signal_d_train = randi([0,QAM_train - 1],[N 1]);
signal_d_train = (1/sqrt(2)) * qammod(signal_d_train,QAM_train);
Hz = [0.5 1.2 1.5 -1];
signal_x_train = filter(Hz,1,signal_d_train);
snr = 10^(inf/10);
energy = mean(abs(signal_x_train(:)).^2);
noise = sqrt(energy.*1/snr/2) * (complex(randn(N,1), randn(N,1)));
signal_x_train = signal_x_train + noise;

% LMS algorithm
for s = M:N
    aux = signal_x_train(s:-1:s-M+1);

```

```

        error(s) = signal_d_train(s-M+1) - weights(:,s)'\*aux;
        weights(:,s+1) = weights(:,s) + 2 * mi * conj(error(s)) *
windowX;
    end

    % Transmission

    % Empty vectors
    N = 5000 + 50;
    error = zeros(N,1);
    weightsShape = weights(:,s+1);
    weights = zeros(M, N);
    weights(:,M) = weightsShape;
    signal_d_hat_300 = zeros(size(signal_d));

    % LMS algorithm
    for s = M:N
        windowX= signal_x(s:-1:s-M+1);
        signal_d_hat_300(s-M+1) = weights(:,s)'\*windowX;
        error(s) = qammod(qamdemod(signal_x(s-M+1),QAM),QAM) -
weights(:,s)'\*windowX;
        weights(:,s+1) = weights(:,s) + 2 * mi * conj(error(s)) *
windowX;
    end

    % Training (500 Samples)
    N = 500;

    % Empty vectors
    error = zeros(N,1);
    weights = zeros(M, N);

    % Signal Model
    QAM_train = 4;
    signal_d_train = randi([0,QAM_train - 1],[N 1]);
    signal_d_train = qammod(signal_d_train,QAM_train);
    Hz = [0.5 1.2 1.5 -1];
    signal_x_train = filter(Hz,1,signal_d_train);
    snr = 10^(inf/10);
    energy = mean(abs(signal_x_train(:)).^2);
    noise = sqrt(energy.*1/snr/2) * (complex(randn(N,1), randn(N,1)));
    signal_x_train = signal_x_train + noise;

    % LMS
    for s = M:N
        aux = signal_x_train(s:-1:s-M+1);
        error(s) = signal_d_train(s-M+1) - weights(:,s)'\*aux;
        weights(:,s+1) = weights(:,s) + 2 * mi * conj(error(s)) *
windowX;
    end

    % Transmission
    N = 5000 + 50;

```

```

% Empty vectors
error = zeros(N,1);
weightsShape = weights(:,s+1);
weights = zeros(M, N);
weights(:,M) = weightsShape;
signal_d_hat_500 = zeros(size(signal_d));

% LMS algorithm
for s = M:N
    windowX= signal_x(s:-1:s-M+1);
    signal_d_hat_500(s-M+1) = weights(:,s)'*windowX;
    error(s) = qamdemod(qamdemod(signal_x(s-M+1),QAM),QAM) -
weights(:,s)'*windowX;
    weights(:,s+1) = weights(:,s) + 2 * mi * conj(error(s)) *
windowX;
end

% Temporal Evolution
selectWindow = 4975:5000;
[~,~,temporalShift] =
alignsignals(qamdemod(signal_d,QAM),qamdemod(signal_d_hat_500,QAM));

    evolutionWindow =
    circshift(qamdemod(signal_d_hat_50,QAM),temporalShift);
    evolutionWindow_50 = evolutionWindow(selectWindow);
    evolutionWindow =
    circshift(qamdemod(signal_d_hat_150,QAM),temporalShift);
    evolutionWindow_150 = evolutionWindow(selectWindow);
    evolutionWindow =
    circshift(qamdemod(signal_d_hat_300,QAM),temporalShift);
    evolutionWindow_300 = evolutionWindow(selectWindow);
    evolutionWindow =
    circshift(qamdemod(signal_d_hat_500,QAM),temporalShift);
    evolutionWindow_500 = evolutionWindow(selectWindow);

    h4 = figure;
    subplot(2,2,1)
    stem(selectWindow,
qamdemod(signal_d(selectWindow),QAM),'-','color',
c_.original, "linewidth", 1, "markersize", 1);
    hold on;
    stem(selectWindow, evolutionWindow_50,'--','color',
c_.estimated, "linewidth", 1, "markersize", 1);
    hold off;
    title('50 Samples');
    xlabel('Sample, N');
    xlim([min(selectWindow) max(selectWindow)]);
    ylabel('Magnitude');
    ylim([0 20])

legend('Original', 'Estimated', 'Location', 'northeastoutside','Orientation', 'Ho
[0.5 0.47 0.0 1], 'Units','normalized');
grid on;

```

```

        legend boxoff
        subplot(2,2,2)
        stem(selectWindow,
qamdemod(signal_d(selectWindow),QAM),'-','color',
c_.original, "linewidth", 1, "markersize", 1);
        hold on;
        stem(selectWindow, evolutionWindow_150,'--','color',
c_.estimated, "linewidth", 1, "markersize", 1);
        hold off;
        title('150 Samples');
        xlabel('Sample, N');
        xlim([min(selectWindow) max(selectWindow)]);
        ylabel('Magnitude');
        grid on;
        subplot(2,2,3)
        stem(selectWindow,
qamdemod(signal_d(selectWindow),QAM),'-','color',
c_.original, "linewidth", 1, "markersize", 1);
        hold on;
        stem(selectWindow, evolutionWindow_300,'--','color',
c_.estimated, "linewidth", 1, "markersize", 1);
        hold off;
        title('300 Samples');
        xlabel('Sample, N');
        xlim([min(selectWindow) max(selectWindow)]);
        ylabel('Magnitude');
        grid on;
        subplot(2,2,4)
        stem(selectWindow,
qamdemod(signal_d(selectWindow),QAM),'-','color',
c_.original, "linewidth", 1, "markersize", 1);
        hold on;
        stem(selectWindow, evolutionWindow_500,'--','color',
c_.estimated, "linewidth", 1, "markersize", 1);
        hold off;
        title('500 Samples');
        xlabel('Sample, N');
        xlim([min(selectWindow) max(selectWindow)]);
        ylabel('Magnitude');
        grid on;

savefig_tight(h4, 'figures/hw3p6b-evolutionSamples', 'both');

% (c) -----
disp('c');

% General Setup
N = 500;
mi = 0.4;
gamma = 1e-3;
order = 15; M = order+1;

% Empty vectors

```

```

error = zeros(N,1);
weights = zeros(M, N);

% Signal Model
SNR = 30;
QAM_train = 4;
signal_d_train = randi([0,QAM_train - 1],[N 1]);
signal_d_train = qammod(signal_d_train,QAM_train);
Hz = [0.5 1.2 1.5 -1];
signal_x_train = filtfilt(Hz,1,signal_d_train);
snr = 10^(inf/10);
energy = mean(abs(signal_x_train(:)).^2);
noise = sqrt(energy.*1/snr/2) * complex(randn(N,1), randn(N,1));;
signal_x_train = signal_x_train + noise;

% LMS
for s = M:N
    aux = signal_x_train(s:-1:s-M+1);
    mi_normalized = mi/(gamma + norm(aux)^2);
    error(s) = signal_d_train(s-M+1) - weights(:,s)'*aux;
    weights(:,s+1) = weights(:,s) + mi_normalized * conj(error(s))
* aux;
end

% Transmission
N = 5000 + 50; % Number of samples

% Empty vectors
error = zeros(N,1);
weights = zeros(M, N);

% Signal Model
SNR = 30;
QAM = 256;
signal_d = randi([0,QAM - 1],[N 1]);
signal_d = qammod(signal_d,QAM); % 4-QAM Pilot Signal.
Hz = [0.5 1.2 1.5 -1];
signal_x = filtfilt(Hz,1,signal_d);
snr = 10^(SNR/10);
energy = mean(abs(signal_x(:)).^2);
noise = sqrt(energy.*1/snr/2)*complex(randn(N,1), randn(N,1));;
signal_x = signal_x + noise;
signal_d_hat = zeros(size(signal_d));

% NLMS
for s = M:N
    aux = signal_x(s:-1:s-M+1);
    mi_normalized = mi/(gamma + norm(aux)^2);
    signal_d_hat(s-M+1) = weights(:,s)'*aux;
    error(s) = qammod(qamdemod(signal_x(s-M+1),QAM),QAM) -
weights(:,s)'*aux;
    weights(:,s+1) = weights(:,s) + mi_normalized * conj(error(s))
* aux;
end

```

```

% MSE
h5 = figure();
semilogy(1:N, abs(error).^2, '-', 'color', c_.nlms , "linewidth",
1);
hold on
semilogy(1:N, repelem(mean(abs(error).^2), N), '--', 'color',
c_.mean , "linewidth", 1);
hold off
xlabel('Samples, N');
xlim([0 N]);
ylabel('MSE');
legend('NLMS', 'Mean', 'Location', 'Best');
grid on;
savefig_tight(h5, 'figures/hw3p6c-MSE', 'both');

% Temporal Evolution
L = 50;
aux = qamdemod(signal_d_hat,QAM);
aux1 = aux(1:L);
aux2 = aux(5000-L:5000);

figure
subplot(211)
stem(1:L, qamdemod(signal_d(1:L),QAM), '-', 'color',
c_.original, "linewidth", 1, "markersize", 3);
hold on;
stem(1:L, aux1, '-', 'color', c_.estimated, "linewidth",
1, "markersize", 3);
hold off;
title('First Samples');
xlabel('Sample, N');
xlim([0 L])
ylabel('Magnitude');

legend('Original', 'Estimated', 'Location', 'northeastoutside', 'Orientation', 'Horizontal',
[0.5 0.47 0.0 1.03], 'Units', 'normalized');
legend boxoff
grid on;
subplot(212)
stem((5000-L):5000, qamdemod(signal_d((5000-
L):5000),QAM), '-', 'color', c_.original, "linewidth", 1, "markersize",
3);
hold on;
stem((5000-L):5000, aux2, '-', 'color', c_.estimated, "linewidth",
1, "markersize", 3);
hold off;
title('Last Samples');
xlabel('Sample, N');
ylabel('Magnitude');
xlim([(5000-L) 5000])
grid on;
% savefig_tight(h5, 'figures/hw3p6c-evolution', 'both');

```

```

% (d) -----
disp('d')
close all;

% General Setup
RMC = 1000;
QAM_train = 4;
QAM_symbols = 4.^(1:4);
SNRdB = 0:10:30;
order = 15; M = order + 1;
mi = 0.4;
gamma = 1e3;
train.N = 500;
trans.N = 5000;
Hz = [0.5 1.2 1.5 -1];

train.error = zeros(train.N,1);
train.weights = zeros(M, train.N);

trans.error = zeros(trans.N,1);
trans.weights = zeros(M, trans.N);

SER = cell(RMC, length(QAM_symbols), length(SNRdB));

tic;
for rmc = 1:RMC
    for iiQAM = 1:length(QAM_symbols)
        for iiSNR = 1:length(SNRdB)
            fprintf('RMC, SNR (%2.0f, %2.0f dB) -- %2.0f-QAM \n',
rmc, SNRdB(iiSNR), QAM_symbols(iiQAM))

                % Training
                signal_d_train = qammod(randi([0,QAM_train - 1],
[train.N 1]),QAM_train);
                signal_x_train = filtfilt(Hz,1,signal_d_train);
                energy = mean(abs(signal_x_train(:)).^2); % Energy
symbol
                signal_x_train = signal_x_train + sqrt(energy.*1/
(10^(inf/10))/2) * complex(randn(train.N,1), randn(train.N,1));

                for s = M:train.N
                    aux = signal_x_train(s:-1:s-M+1);
                    mi_normalized = mi/(gamma + norm(aux)^2);
                    train.error(s) = signal_d_train(s-M+1) -
train.weights(:,s)'*aux;
                    train.weights(:,s+1) = train.weights(:,s) +
mi_normalized * conj(train.error(s)) * aux;
                end

                % Transmission
                QAM = QAM_symbols(iiQAM);
                signal_d = qammod(randi([0,QAM - 1],[trans.N 1]),QAM);
                signal_x = filtfilt(Hz,1,signal_d);

```

```

        energy = mean(abs(signal_x(:)).^2); % Energy symbol
pilot.
        signal_x = signal_x + sqrt(energy.*1/
(10^(SNRdB(iiSNR)/10))/2) * (randn(trans.N,1) + 1i*randn(trans.N,1));
        signal_d_hat = zeros(size(signal_d));

% NLMS
for s = M:trans.N
    aux = signal_x(s:-1:s-M+1);
    mi_normalized = mi/(gamma + norm(aux)^2);
    signal_d_hat(s-M+1) = trans.weights(:,s)'*aux;
    trans.error(s) = qammod(qamdemod(signal_x(s-M
+1),QAM),QAM) - trans.weights(:,s)'*aux;
    trans.weights(:,s+1) = trans.weights(:,s) +
mi_normalized * conj(trans.error(s)) * aux;
end

        SER{rmc, iiSNR, iiQAM} = sum(qamdemod(signal_d,QAM) ~=
qamdemod(signal_d_hat,QAM)) / length(qamdemod(signal_d,QAM));

    end
end
fprintf('-----\n\n')
end

t = toc;
disp(t)

c_ =
struct('QAM4', 'y', 'QAM16', 'k', 'QAM64', 'r', 'QAM256', 'b', 'mean', 'k');

h6 = figure();
semilogy(SNRdB, mean(cell2mat(SER(:, :, 1)), 1), '-', 'color',
c_.QAM4, 'linewidth', 1.5);
hold on;
semilogy(SNRdB, mean(cell2mat(SER(:, :, 2)), 1), '-', 'color',
c_.QAM16, 'Marker', 's', 'MarkerFaceColor', c_.QAM16, 'linewidth',
1.5);
semilogy(SNRdB, mean(cell2mat(SER(:, :, 3)), 1), '-.', 'color',
c_.QAM64, 'Marker', 'o', 'MarkerFaceColor', c_.QAM64, 'linewidth',
1.5);
semilogy(SNRdB, mean(cell2mat(SER(:, :, 4)), 1), '--', 'color',
c_.QAM256, 'Marker', '^', 'MarkerFaceColor', c_.QAM256, 'linewidth',
1.5);
hold off;
xlabel('SNR (dB)');
ylabel('SER');
xticks(SNRdB);
ylim([2e-3 2]);
legend('4-QAM', '16-QAM', '64-QAM', '256-
QAM', 'Location', 'Best');
grid minor

save('hw3p6d.mat', 'SNRdB', 'SER', 'c_');

```

```

    savefig_tight(h6, 'figures/hw3p6d-SER', 'both');

    disp('pause');
    pause();
    return
end

```

HOMWORK 4 - PROBLEM 1

```

function [y, weights] = hw4plrls(signal_x, signal_d, M, lambda,
    delta, fixcoeff)
    N = length(signal_d);
    error = zeros(N,1);
    weights = zeros(M, N);
    Rd = delta*eye(M);
    y = zeros(N,1);
    weights(1,1) = 1;

    for n = 2:(N - M - 1)
        Rd = (1/lambda)*(Rd - (Rd*signal_x(n:n+M-1)*signal_x(n:n
+M-1)')*Rd)/(lambda + signal_x(n:n+M-1)'*Rd*signal_x(n:n+M-1));
        error(n) = signal_d(n) - weights(:,n-1)' * signal_x(n:n+M-1);
        weights(:,n) = weights(:,n-1) + Rd*error(n)*signal_x(n:n+M-1);
        if fixcoeff
            weights(1,n) = 1; % Impose first coeff fix
        end
        y(n) = weights(:,n-1)' * signal_x(n:n+M-1);
    end

end

function hw4pl(varargin)
    disp('hw4pl')
    c_ = struct('original', [57 106 177]./255, 'fixcoef', [204 37
41]./255, 'freecoeff', [62 150 81]./255);

    % General Setup
    N = 100;
    order = 2; M = order + 1;
    lambda = 0.98;
    delta = 1;

    % Signal Model
    t = linspace(-3*pi,3*pi,N).';
    signal_d = cos(pi*t/3);
    SNR_dB = 10;
    noise = sqrt((1/(10^(SNR_dB/10)))/2).*randn(N,1);
    signal_x = signal_d + noise;

    [fixcoef.y, fixcoef.weights] = filter_hw.hw4plrls(signal_x,
    signal_d, M, lambda, delta, true);

```

```

[freecoeff.y, freecoeff.weights] = filter_hw.hw4p1rls(signal_x,
signal_d, M, lambda, delta, false);

filter_hw.mat2txt('hw4p1coef.txt',
fixcoef.weights(:,1:10).', 'w', 'coef fix');
filter_hw.mat2txt('hw4p1coef.txt',
freecoeff.weights(:,1:10).', 'a', 'free fix');

% MSE Curve
h1 = figure();
plot(signal_d, '-', 'color', 'k', 'linewidth', 1);
hold on;
plot(fixcoef.y, '--', 'color', c_.fixcoef,
'Marker', '^', 'MarkerFaceColor',
c_.fixcoef, 'MarkerIndices', 1:20:length(fixcoef.y), 'linewidth', 1);
plot(freecoeff.y, '-.', 'color', c_.freecoeff,
'Marker', 'o', 'MarkerFaceColor',
c_.freecoeff, 'MarkerIndices', 1:25:length(freecoeff.y), 'linewidth',
1);
hold off;
xlabel('Samples, N');
ylabel('Magnitude');
legend('Original (SNR = 10 dB)', 'Fix Coef', 'Free
Coef', 'Location', 'Best');
grid on;
savefig_tight(h1, 'figures/hw4p1', 'both');

end

```

HOMWORK 4 - PROBLEM 3

```

function [error, weights] = hw4p3rls(signal_d, M, SNR_dB, lambda)
    N = length(signal_d);
    error = zeros(N,1);
    weights = zeros(M, N);

    noise = sqrt((1/(10^(SNR_dB/10)))/2).*randn(N,1);
    signal_x = signal_d + noise; % Defining delta by the inverse of
the signal energy

    delta = 1/(sum(signal_x.^2)/length(signal_x));
    Rd = delta*eye(M);

    signal_d = signal_d(M:end,1);
    for ss = 2:(N - M - 1)
        Rd = (1/lambda)*(Rd - (Rd*signal_x(ss:ss+M-1)*signal_x(ss:ss
+M-1)')*Rd)/(lambda + signal_x(ss:ss+M-1)'*Rd*signal_x(ss:ss+M-1));
        error(ss) = signal_d(ss) - weights(:,ss-1)' * signal_x(ss:ss
+M-1);
        weights(:,ss) = weights(:,ss-1) + Rd*error(ss)*signal_x(ss:ss
+M-1);
    end
    weights = flip(weights);

```

```

end

function hw4p3(varargin)
    disp('hw4p3');

    c_ = struct('original', [57 106 177]./255, 'estimated', [204 37
41]./255, 'nlms', [107 76 154]./255, 'mean', 'k');

    % General Setup
    N = 510;
    A.lambda = 0.9;
    B.lambda = 0.99;
    C.lambda = 0.999;

    % Order = 2
    -----
    order = 2; M = order + 1;
    SNR_dB = 3;

    % Signal Model
    t = linspace(-pi,pi,N).';
    signal_d = sin(2*pi*t); % Generating the noisy received signal.

    % Change: M, SNR, lambda
    [A.error, A.weights] = filter_hw.hw4p3rls(signal_d, M, SNR_dB,
A.lambda);
    [B.error, B.weights] = filter_hw.hw4p3rls(signal_d, M, SNR_dB,
B.lambda);
    [C.error, C.weights] = filter_hw.hw4p3rls(signal_d, M, SNR_dB,
C.lambda);

    % Plot - 3 dB
    h1 = figure();
    subplot(2,2,1)
    semilogy(1:N, A.error.^2, '-', 'color', c_.nlms, "linewidth",
1, "markersize", 8);
    hold on
    semilogy(1:N, repelem(mean(A.error.^2), N), '--', 'color',
c_.mean, "linewidth", 1);
    hold off
    xlabel('Samples, N');
    xlim([0 N-10]);
    ylim([1e-8 1e0]);
    ylabel('MSE');
    legend(strcat(sprintf('RLS (M = %2.0f, SNR = %2.0f$ dB,', order,
SNR_dB), ' $\lambda$ = ', num2str(A.lambda), ')'), strcat('Mean = ',
num2str(mean(A.error.^2))), 'interpreter', 'latex', 'Orientation', 'Vertical', 'L
legend boxoff
    grid on;

    subplot(2,2,2)
    semilogy(1:N, B.error.^2, '-', 'color', c_.nlms, "linewidth",
1, "markersize", 8);

```

```

        hold on
        semilogy(1:N, repelem(mean(B.error.^2), N), '--', 'color',
c_.mean, "linewidth", 1);
        hold off
        xlabel('Samples, N');
        xlim([0 N-10]);
        ylim([1e-8 1e0]);
        ylabel('MSE');
        legend(strcat(sprintf('RLS (M = %2.0f, SNR = %2.0f$ dB,', order,
SNR_dB), ' $\lambda$ = ', num2str(B.lambda), ')'), strcat('Mean = ',
num2str(mean(B.error.^2))), 'interpreter', 'latex', 'Orientation', 'Vertical', 'L
        legend boxoff
        grid on;

        subplot(2,2,3)
        plot(1:N, A.weights(1,:), '-', 'color', c_.original, "linewidth",
1);
        hold on;
        plot(1:N, A.weights(2,:), '--', 'color', c_.estimated, "linewidth",
1);
        hold off;
        xlabel('Samples, N');
        ylabel('Magnitude');
        xlim([0 N-10]);

        legend('$w_0$', '$w_1$', 'interpreter', 'latex', 'Orientation', 'Horizontal', 'Lo
        legend boxoff
        grid on;

        subplot(2,2,4)
        plot(1:N, B.weights(1,:), '-', 'color', c_.original, "linewidth",
1);
        hold on;
        plot(1:N, B.weights(2,:), '--', 'color', c_.estimated, "linewidth",
1);
        hold off;
        xlabel('Samples, N');
        ylabel('Magnitude');
        xlim([0 N-10]);

        legend('$w_0$', '$w_1$', 'interpreter', 'latex', 'Orientation', 'Horizontal', 'Lo
        legend boxoff
        grid on;

        % savefig_tight(h1, 'figures/hw4p3-fig1', 'both');

        h2 = figure();
        subplot(2,1,1)
        semilogy(1:N, C.error.^2, '-', 'color', c_.nlms, "linewidth",
1, "markersize", 8);
        hold on
        semilogy(1:N, repelem(mean(C.error.^2), N), '--', 'color',
c_.mean, "linewidth", 1);
        hold off

```

```

xlabel('Samples, N');
xlim([0 N-10]);
ylim([1e-8 1e0]);
ylabel('MSE');
legend(strcat(sprintf('RLS (M = %2.0f, SNR = %2.0f$ dB', order,
SNR_dB), ' $\lambda$ = ', num2str(C.lambda), ')'), strcat('Mean = ',
num2str(mean(B.error.^2))), 'interpreter', 'latex', 'Orientation', 'Vertical', 'L
legend boxoff
grid on;

subplot(2,1,2)
plot(1:N, C.weights(1,:), '-', 'color', c_.original, "linewidth",
1);
hold on;
plot(1:N, C.weights(2,:), '--', 'color', c_.estimated, "linewidth",
1);
hold off;
xlabel('Samples, N');
ylabel('Magnitude');
xlim([0 N-10]);

legend('$w_0$', '$w_1$', 'interpreter', 'latex', 'Orientation', 'Horizontal', 'Lo
legend boxoff
grid on;

% savefig_tight(h2, 'figures/hw4p3-fig2', 'both');

pause;
close all;

SNR_dB = inf;

% Signal Model
t = linspace(-pi,pi,N).';
signal_d = sin(2*pi*t); % Generating the noisy received signal.

% Change: M, SNR, lambda
[A.error, A.weights] = filter_hw.hw4p3rls(signal_d, M, SNR_dB,
A.lambda);
[B.error, B.weights] = filter_hw.hw4p3rls(signal_d, M, SNR_dB,
B.lambda);
[C.error, C.weights] = filter_hw.hw4p3rls(signal_d, M, SNR_dB,
C.lambda);

% Plot - inf dB
h3 = figure();
subplot(2,2,1)
semilogy(1:N, A.error.^2, '-', 'color', c_.nlms, "linewidth",
1, "markersize", 8);
hold on
semilogy(1:N, repelem(mean(A.error.^2), N), '--', 'color',
c_.mean, "linewidth", 1);
hold off
xlabel('Samples, N');

```

```

        xlim([0 N-10]);
        ylim([1e-8 1e0]);
        ylabel('MSE');
        legend(strcat(sprintf('RLS (M = %2.0f, SNR = %2.0f$ dB,', order,
SNR_dB), ' $\lambda$ = ', num2str(A.lambda), ')'), strcat('Mean = ',
num2str(mean(A.error.^2))), 'interpreter', 'latex', 'Orientation', 'Vertical', 'L
        legend boxoff
        grid on;

        subplot(2,2,2)
        semilogy(1:N, B.error.^2, '-', 'color', c_.nlms, "linewidth",
1, "markersize", 8);
        hold on
        semilogy(1:N, repelem(mean(B.error.^2), N), '--', 'color',
c_.mean, "linewidth", 1);
        hold off
        xlabel('Samples, N');
        xlim([0 N-10]);
        ylim([1e-8 1e0]);
        ylabel('MSE');
        legend(strcat(sprintf('RLS (M = %2.0f, SNR = %2.0f$ dB,', order,
SNR_dB), ' $\lambda$ = ', num2str(B.lambda), ')'), strcat('Mean = ',
num2str(mean(B.error.^2))), 'interpreter', 'latex', 'Orientation', 'Vertical', 'L
        legend boxoff
        grid on;

        subplot(2,2,3)
        plot(1:N, A.weights(1,:), '-', 'color', c_.original, "linewidth",
1);
        hold on;
        plot(1:N, A.weights(2,:), '--', 'color', c_.estimated, "linewidth",
1);
        hold off;
        xlabel('Samples, N');
        ylabel('Magnitude');
        xlim([0 N-10]);

        legend('$w_0$', '$w_1$', 'interpreter', 'latex', 'Orientation', 'Horizontal', 'Lo
        legend boxoff
        grid on;

        subplot(2,2,4)
        plot(1:N, B.weights(1,:), '-', 'color', c_.original, "linewidth",
1);
        hold on;
        plot(1:N, B.weights(2,:), '--', 'color', c_.estimated, "linewidth",
1);
        hold off;
        xlabel('Samples, N');
        ylabel('Magnitude');
        xlim([0 N-10]);

        legend('$w_0$', '$w_1$', 'interpreter', 'latex', 'Orientation', 'Horizontal', 'Lo
        legend boxoff

```

```

grid on;

% savefig_tight(h3, 'figures/hw4p3-fig3', 'both');

h4 = figure();
subplot(2,1,1)
semilogy(1:N, C.error.^2, '-', 'color', c_.nlms, "linewidth",
1, "markersize", 8);
hold on
semilogy(1:N, repelem(mean(C.error.^2), N), '--', 'color',
c_.mean, "linewidth", 1);
hold off
xlabel('Samples, N');
xlim([0 N-10]);
ylim([1e-8 1e0]);
ylabel('MSE');
legend(strcat(sprintf('RLS (M = %2.0f, SNR = %2.0f$ dB', order,
SNR_dB), ' $\lambda$ = ', num2str(C.lambda), ')'), strcat('Mean = ',
num2str(mean(B.error.^2))), 'interpreter', 'latex', 'Orientation', 'Vertical', 'L
legend boxoff
grid on;

subplot(2,1,2)
plot(1:N, C.weights(1,:), '-', 'color', c_.original, "linewidth",
1);
hold on;
plot(1:N, C.weights(2,:), '--', 'color', c_.estimated, "linewidth",
1);
hold off;
xlabel('Samples, N');
ylabel('Magnitude');
xlim([0 N-10]);

legend('$w_0$', '$w_1$', 'interpreter', 'latex', 'Orientation', 'Horizontal', 'Lo
legend boxoff
grid on;

% savefig_tight(h4, 'figures/hw4p3-fig4', 'both');

pause;
close all;

% Order = 3
-----
order = 3; M = order + 1;
SNR_dB = 3;

% Signal Model
t = linspace(-pi, pi, N).';
signal_d = sin(2*pi*t); % Generating the noisy received signal.

% Change: M, SNR, lambda
[A.error, A.weights] = filter_hw.hw4p3rls(signal_d, M, SNR_dB,
A.lambda);

```

```

[B.error, B.weights] = filter_hw.hw4p3rls(signal_d, M, SNR_dB,
B.lambda);
[C.error, C.weights] = filter_hw.hw4p3rls(signal_d, M, SNR_dB,
C.lambda);

% Plot - 3 dB
h5 = figure();
subplot(2,2,1)
semilogy(1:N, A.error.^2, '-', 'color', c_.nlms, "linewidth",
1, "markersize", 8);
hold on
semilogy(1:N, repelem(mean(A.error.^2), N), '--', 'color',
c_.mean, "linewidth", 1);
hold off
xlabel('Samples, N');
xlim([0 N-10]);
ylim([1e-8 1e0])
ylabel('MSE');
legend(strcat(sprintf('RLS (M = %2.0f, SNR = %2.0f$ dB,', order,
SNR_dB), ' $\lambda$ = ', num2str(A.lambda), ')'), strcat('Mean = ',
num2str(mean(A.error.^2))), 'interpreter', 'latex', 'Orientation', 'Vertical', 'L
legend boxoff
grid on;

subplot(2,2,2)
semilogy(1:N, B.error.^2, '-', 'color', c_.nlms, "linewidth",
1, "markersize", 8);
hold on
semilogy(1:N, repelem(mean(B.error.^2), N), '--', 'color',
c_.mean, "linewidth", 1);
hold off
xlabel('Samples, N');
xlim([0 N-10]);
ylim([1e-8 1e0])
ylabel('MSE');
legend(strcat(sprintf('RLS (M = %2.0f, SNR = %2.0f$ dB,', order,
SNR_dB), ' $\lambda$ = ', num2str(B.lambda), ')'), strcat('Mean = ',
num2str(mean(B.error.^2))), 'interpreter', 'latex', 'Orientation', 'Vertical', 'L
legend boxoff
grid on;

subplot(2,2,3)
plot(1:N, A.weights(1,:), '-', 'color', c_.original, "linewidth",
1);
hold on;
plot(1:N, A.weights(2,:), '--', 'color', c_.estimated, "linewidth",
1);
hold off;
xlabel('Samples, N');
ylabel('Magnitude');
xlim([0 N-10]);

legend('$w_0$', '$w_1$', 'interpreter', 'latex', 'Orientation', 'Horizontal', 'Lo
legend boxoff

```

```

        grid on;

        subplot(2,2,4)
        plot(1:N, B.weights(1,:), '-', 'color', c_.original, "linewidth",
1);
        hold on;
        plot(1:N, B.weights(2,:), '--', 'color', c_.estimated, "linewidth",
1);
        hold off;
        xlabel('Samples, N');
        ylabel('Magnitude');
        xlim([0 N-10]);

legend('$w_0$', '$w_1$', 'interpreter', 'latex', 'Orientation', 'Horizontal', 'Lo
legend boxoff
grid on;

% savefig_tight(h5, 'figures/hw4p3-fig5', 'both');

h6 = figure();
subplot(2,1,1)
semilogy(1:N, C.error.^2, '-', 'color', c_.nlms, "linewidth",
1, "markersize", 8);
hold on
semilogy(1:N, repelem(mean(C.error.^2), N), '--', 'color',
c_.mean, "linewidth", 1);
hold off
xlabel('Samples, N');
xlim([0 N-10]);
ylim([1e-8 1e0]);
ylabel('MSE');
legend(sprintf('RLS (M = %2.0f, SNR = %2.0f$ dB,', order,
SNR_dB), ' $\lambda$ = ', num2str(C.lambda), ')', strcat('Mean = ',
num2str(mean(B.error.^2))), 'interpreter', 'latex', 'Orientation', 'Vertical', 'L
legend boxoff
grid on;

subplot(2,1,2)
plot(1:N, C.weights(1,:), '-', 'color', c_.original, "linewidth",
1);
hold on;
plot(1:N, C.weights(2,:), '--', 'color', c_.estimated, "linewidth",
1);
hold off;
xlabel('Samples, N');
ylabel('Magnitude');
xlim([0 N-10]);

legend('$w_0$', '$w_1$', 'interpreter', 'latex', 'Orientation', 'Horizontal', 'Lo
legend boxoff
grid on;

% savefig_tight(h6, 'figures/hw4p3-fig6', 'both');

```

```

pause;
close all;

SNR_dB = inf;

% Signal Model
t = linspace(-pi,pi,N).';
signal_d = sin(2*pi*t); % Generating the noisy received signal.

% Change: M, SNR, lambda
[A.error, A.weights] = filter_hw.hw4p3rls(signal_d, M, SNR_dB,
A.lambda);
[B.error, B.weights] = filter_hw.hw4p3rls(signal_d, M, SNR_dB,
B.lambda);
[C.error, C.weights] = filter_hw.hw4p3rls(signal_d, M, SNR_dB,
C.lambda);

% Plot - inf dB
h7 = figure();
subplot(2,2,1)
semilogy(1:N, A.error.^2, '-', 'color', c_.nlms, "linewidth",
1, "markersize", 8);
hold on
semilogy(1:N, repelem(mean(A.error.^2), N), '--', 'color',
c_.mean, "linewidth", 1);
hold off
xlabel('Samples, N');
xlim([0 N-10]);
ylim([1e-8 1e0])
ylabel('MSE');
legend(strcat(sprintf('RLS (M = %2.0f, SNR = %2.0f$ dB,', order,
SNR_dB), ' $\lambda$ = ', num2str(A.lambda), ')'), strcat('Mean = ',
num2str(mean(A.error.^2))), 'interpreter', 'latex', 'Orientation', 'Vertical', 'L
legend boxoff
grid on;

subplot(2,2,2)
semilogy(1:N, B.error.^2, '-', 'color', c_.nlms, "linewidth",
1, "markersize", 8);
hold on
semilogy(1:N, repelem(mean(B.error.^2), N), '--', 'color',
c_.mean, "linewidth", 1);
hold off
xlabel('Samples, N');
xlim([0 N-10]);
ylim([1e-8 1e0])
ylabel('MSE');
legend(strcat(sprintf('RLS (M = %2.0f, SNR = %2.0f$ dB,', order,
SNR_dB), ' $\lambda$ = ', num2str(B.lambda), ')'), strcat('Mean = ',
num2str(mean(B.error.^2))), 'interpreter', 'latex', 'Orientation', 'Vertical', 'L
legend boxoff
grid on;

subplot(2,2,3)

```

```

    plot(1:N, A.weights(1,:), '-', 'color', c_.original, "linewidth",
1);
    hold on;
    plot(1:N, A.weights(2,:), '--', 'color', c_.estimated, "linewidth",
1);
    hold off;
    xlabel('Samples, N');
    ylabel('Magnitude');
    xlim([0 N-10]);

legend('$w_0$', '$w_1$', 'interpreter', 'latex', 'Orientation', 'Horizontal', 'Lo
    legend boxoff
    grid on;

    subplot(2,2,4)
    plot(1:N, B.weights(1,:), '-', 'color', c_.original, "linewidth",
1);
    hold on;
    plot(1:N, B.weights(2,:), '--', 'color', c_.estimated, "linewidth",
1);
    hold off;
    xlabel('Samples, N');
    ylabel('Magnitude');
    xlim([0 N-10]);

legend('$w_0$', '$w_1$', 'interpreter', 'latex', 'Orientation', 'Horizontal', 'Lo
    legend boxoff
    grid on;

    savefig_tight(h7, 'figures/hw4p3-fig7', 'both');

    h8 = figure();
    subplot(2,1,1)
    semilogy(1:N, C.error.^2, '-', 'color', c_.nlms, "linewidth",
1, "markersize", 8);
    hold on
    semilogy(1:N, repelem(mean(C.error.^2), N), '--', 'color',
c_.mean, "linewidth", 1);
    hold off
    xlabel('Samples, N');
    xlim([0 N-10]);
    ylim([1e-8 1e0]);
    ylabel('MSE');
    legend(sprintf('RLS (M = %2.0f, SNR = %2.0f$ dB,', order,
SNR_dB), ' $\lambda$ = ', num2str(C.lambda), ')'), strcat('Mean = ',
num2str(mean(B.error.^2))), 'interpreter', 'latex', 'Orientation', 'Vertical', 'L
    legend boxoff
    grid on;

    subplot(2,1,2)
    plot(1:N, C.weights(1,:), '-', 'color', c_.original, "linewidth",
1);
    hold on;

```

```

    plot(1:N, C.weights(2,:), '--', 'color', c_.estimated, "linewidth",
1);
    hold off;
    xlabel('Samples, N');
    ylabel('Magnitude');
    xlim([0 N-10]);

    legend('$w_0$', '$w_1$', 'interpreter', 'latex', 'Orientation', 'Horizontal', 'Lo
    legend boxoff
    grid on;

    savefig_tight(h8, 'figures/hw4p3-fig8', 'both');

end

```

VERBOSE DETAILS

```

function export_fig(Activate, h, filename)
    if Activate
        savefig_tight(h, filename, 'both');
        filter_hw.verbose_save(filename);
    else
        pause(2)
        close(h);
    end
end

function verbose_save(filename)
    fprintf('Saving Results for:\n\t %s \n', filename);
end

```

SAVE DATA TO TXT FILE

```

function mat2txt(filename, X, permission, header)
% ND.MAT2TXT Write a matrix X into a txt file
% mat2txt(filename, X, 'w', header) - Overwrite the file
% mat2txt(filename, X, 'a', header) - Append to the file end
%
% See also.
    [I, J] = size(X);
    fileID = fopen(filename, permission);
    fprintf(fileID, [repelem('-', strlength(header)+3), '\n',
header, ...
        '\n', repelem('-', strlength(header)+3), '\n']);
    fprintf(fileID, 'X(%d, %d)\n', I, J);
    for ii = 1:I
        for jj = 1:J
            fprintf(fileID, ' %2.4f', X(ii,jj));
        end
        fprintf(fileID, ';\n');
    end
end

```

```
        end
        fprintf(fileID, '\n');
        fclose(fileID);
    end
```

```
% end methods list
```

```
end
end
```

```
ans =
```

```
    filter_hw with no properties.
```

```
Published with MATLAB® R2021a
```

Função Main

[TIP7188 - Filtragem Adaptativa] Author: Lucas Abdalah

main.m

```
clearvars;  
close all;  
clc; pause(0.1)  
  
% publish('main.m', 'pdf');  
% publish('filter_hw.m', 'pdf');  
  
% filter_hw.hw2p5();  
% filter_hw.hw3p4();  
% filter_hw.hw3p5();  
% filter_hw.hw3p6();  
% filter_hw.hw4p1();  
% filter_hw.hw4p3();
```

Published with MATLAB® R2021a